

硕士学位论文

**基于近红外光谱技术检测加工中绿茶含水
率的方法研究**

**Research on the method for detecting the moisture
content of green tea based on NIRS**

一 级 学 科 **计算机科学与技术**

二 级 学 科 **计算机科学与技术**

作 者 姓 名 **204711074**

指 导 教 师

2023 年 4 月

中图分类号 TP391

学校代码 10533

UDC 004.9

学位类别 学术学位

硕士学位论文

基于近红外光谱技术检测加工中绿茶含水率的方法研究

Research on the method for detecting the moisture content of green tea based on NIRS

作 者 姓 名	204711074
一 级 学 科	计算机科学与技术
二 级 学 科	计算机科学与技术
研 究 方 向	计算机应用技术
二级培养单位	计算机学院
指 导 教 师	
副 指 导 教 师	

论文答辩日期_____ 答辩委员会主席_____

中 南 大 学

2023 年 4 月

学位论文原创性声明

本人郑重声明，所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了论文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中南大学或其他教育机构的学位或证书而使用过的材料。与我共同工作的同志对本研究所作的贡献均已在论文中作了明确的说明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

学位论文作者签名：_____ 日期：_____ 年 ____ 月 ____ 日

学位论文版权使用授权书

本学位论文作者和指导教师完全了解中南大学有关保留、使用学位论文的规定：即学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索和公开传播，可以采用复印、缩印或其它手段保存和汇编学位论文。本人同意按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。本人保证：毕业后以学位论文内容发表的论文作者单位注明中南大学；学位论文电子文档的内容和纸质学位论文的内容相一致。

延缓公开论文延缓到期后适用本授权书，涉密论文在解密后适用本授权书。

本学位论文属于：(请在以下相应方框内打“√”)

☐ 公开

☐ 延缓公开，延缓期限（____ 年 ____ 月 ____ 日至 ____ 年 ____ 月 ____ 日）

学位论文作者签名：_____

指导教师签名：_____

日期：_____ 年 ____ 月 ____ 日

日期：_____ 年 ____ 月 ____ 日

(填写阿拉伯数字)

基于近红外光谱技术检测加工中绿茶含水率的方法研究

摘要:

含水率是影响绿茶加工参数的关键因素。传统测量方法时间长、预测精度低，限制了现代绿茶加工技术的发展。近红外光谱技术(NIRS)是一种基于分子振动引起的光谱吸收现象的方法，结合化学计量学可以实现绿茶含水率的检测，促进茶叶行业的标准化和自动化生产。然而，NIRS 应用于含水率检测仍面临数据获取、光谱预处理、回归模型性能和泛化能力等挑战。本文采用多种方法去解决上述问题，包括获取规范实验数据、奇异样本识别、特征波长、自适应遗传算法优化模型超参数以及改进的 Stacking 集成学习算法，以此实现绿茶加工中含水率的快速无损检测。

(1) 为了获得准确的近红外光谱数据，本文从绿茶加工的七个步骤中分别进行样品采集，并使用便携式近红外光谱仪获取了所有样品的漫反射吸收光谱。为减少数据采集误差，按照 GB5009.3-2016 国家标准测定了样本的含水率。通过蒙特卡洛交叉验证法检测出 18 个可疑奇异样本，并对这些样本进行了二次检验，最终剔除了六个奇异样本，排除偶然性因素的影响，确保了后续研究中光谱数据的质量。

(2) 为了快速准确的检测绿茶含水率，防止模型失真和过拟合现象，使用 SPXY 算法将数据集划分为训练集和预测集。为了获取最优的建模效果，消除采集过程中受到仪器设备、样品表面污染、变形以及实验环境等干扰因素。使用七种方法进行预处理，并建立偏最小二乘法回归(PLSR)模型，以找出最佳的预处理方法。结果表明，SG 平滑方法在 PLSR 模型中表现最佳，合适的预处理方法可以提高建立定量模型的准确性和预测性能。为了降低原始光谱中冗余信息和干扰信息对回归模型的影响，本文采用了主成分分析(PCA)、竞争性自适应重采样加权算法(CARS)和连续投影算法(SPA)三种方法提取特征波长，并分别建立 PLSR、支持向量回归(SVR)和 BP 神经网络(BPNN)三种回归模型，对不同的特征波长变量进行分析和评价，以确定其在不同建模方法中所构建的最优模型的性能表现。结果表明 PCA 提取特征波长后建立的 SVR 模型的表现最佳，参与建模的变量有 15 个，其预测集决定系数(R_p^2)为 0.9760，预测集均方根误

差 (RMSEP) 为 1.94%，相对预测偏差 (RPD) 为 6.4587，合适的特征波长提取方法可以提高模型的建模速度和预测精度。

(3) 为了解决单一模型精度低、不稳定和泛化能力差的问题，引入 Stacking 集成学习模型来建立绿茶含水率模型。通过自适应遗传算法 (AGA)，优化了 PLSR、SVR、BPNN、随机森林 (RF) 和自适应增强算法 (AdaBoost) 等五种回归模型的超参数，提高 Stacking 基学习器的性能。在基学习器组合的选择上，引入 Kendall 相关性分析进行改进，并建立了 16 种基学习器的组合，验证了 Kendall 相关性分析的有效性和准确性。通过结合 AGA 和 Kendall 相关性分析，建立了以 AdaBoost、PLSR 和 BPNN 作为基学习器，RF 作为元学习器的改进 Stacking 含水率预测模型，其预测效果最佳，其中 R_p^2 为 0.9953，RMSEP 为 0.86%，RPD 为 14.5527。

本文旨在研究一种快速、无损的方法来检测绿茶含水率。通过应用特征波长提取方法和改进的 Stacking 集成学习，提升了含水率模型的鲁棒性和预测精度。证实了特征波长提取方法和 Stacking 集成学习在绿茶含水率检测中的有效性和可行性。这项研究为绿茶含水率检测提供了一种新的技术实现，同时也为其他茶叶的含水率检测提供了新的思路。

图 37 幅，表 14 个，参考文献 82 篇

关键词：含水率；近红外光谱技术；定量模型；特征波长提取；Stacking 集成学习

分类号：TP391

Research on the method for detecting the moisture content of green tea based on NIRS

Abstract: Moisture content is a key factor affecting the parameters of green tea processing. Traditional measurement methods, with their long measurement time and low prediction accuracy, have limited the development of modern green tea processing technology. Near-infrared spectroscopy (NIRS), a method based on the spectral absorption phenomenon caused by molecular vibration, combined with chemometrics, can be used to detect the moisture content of green tea, promoting the standardization and automation of the tea industry. However, the application of NIRS to moisture content detection still faces challenges such as data acquisition, spectral pretreatment, regression model performance and generalization ability. This article uses various methods to solve these problems, including obtaining standardized experimental data, identifying singular samples, selecting characteristic wavelengths, optimizing model hyperparameters with adaptive genetic algorithm, and improving the Stacking ensemble learning algorithm, in order to achieve fast and non-destructive detection of moisture content in green tea processing.

(1) In order to obtain accurate near-infrared spectroscopy data, samples were collected from each of the seven steps in green tea processing, and diffuse reflectance absorption spectra were obtained for all samples using a portable near-infrared spectrometer. To reduce data acquisition errors, the moisture content of the samples was measured according to the GB5009.3-2016 national standard. Through Monte Carlo cross-validation, 18 suspicious singular samples were detected, and these samples were subjected to a second verification, resulting in the elimination of six singular samples, thereby eliminating the influence of accidental factors and ensuring the quality of spectral data in subsequent research.

(2) In order to rapidly and accurately detect the moisture content of green tea and prevent model distortion and overfitting, the SPXY algorithm was used to partition the dataset into a training set and a prediction set. To obtain the optimal modeling performance and eliminate interference factors

such as instrument equipment, sample surface contamination, deformation, and experimental environment during the data collection process, seven preprocessing methods were employed. A partial least squares regression (PLSR) model was established to determine the best preprocessing method, and the results showed that the SG smoothing method performed the best in the PLSR model. Appropriate preprocessing methods can improve the accuracy and predictive performance of the quantitative model. To reduce the impact of redundant and interfering information from the original spectra on the regression model, three methods, namely principal component analysis (PCA), competitive adaptive reweighted sampling (CARS), and successive projections algorithm (SPA), were used to extract feature wavelengths. PLSR, support vector regression (SVR), and backpropagation neural network (BPNN) regression models were established using the feature wavelengths extracted by each method. The performance of the different feature wavelength variables in the optimal models constructed by different modeling methods was analyzed and evaluated. The results showed that the SVR model established after feature wavelength extraction by PCA performed the best, with 15 variables involved in the modeling process. The determination coefficient (R_p^2) of the prediction set was 0.9760, the root mean square error of prediction (RMSEP) was 1.94%, and the relative prediction deviation (RPD) was 6.4587. The use of appropriate feature wavelength extraction methods can improve the modeling speed and prediction accuracy of the model.

(3) To address the issues of low accuracy, instability, and poor generalization ability of a single model, a Stacking ensemble learning model was introduced to establish the moisture content model of green tea. The hyperparameters of five regression models, namely PLSR, SVR, BPNN, random forest (RF), and AdaBoost, were optimized using the adaptive genetic algorithm (AGA) to enhance the performance of the base learners in the Stacking model. In the selection of base learner combinations, Kendall correlation analysis was introduced for improvement, and 16 combinations of base learners were established to validate the effectiveness and accuracy of Kendall correlation analysis. By combining AGA and Kendall correlation analysis, an improved Stacking moisture prediction model was es-

tablished with AdaBoost, PLSR, and BPNN as base learners and RF as the meta-learner, which achieved the best prediction performance. The R_P^2 was 0.9953, RMSEP was 0.86%, and RPD was 14.5527.

This study aims to investigate a fast and non-destructive method for detecting the moisture content of green tea. By applying feature wavelength extraction methods and an improved Stacking ensemble learning approach, the robustness and prediction accuracy of the moisture content model were enhanced. The effectiveness and feasibility of feature wavelength extraction methods and Stacking ensemble learning in the detection of green tea moisture content were confirmed. This research provides a new technological implementation for the detection of green tea moisture content and offers new insights for the moisture content detection of other types of tea.

Keywords: Moisture content; NIRS; Quantitative regression; Feature wavelength extraction; Stacking ensemble learning

Classification: TP391

目 录

摘要	I
ABSTRACT	III
目录	VI
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究现状	2
1.2.1 绿茶含水率检测研究现状	2
1.2.2 近红外光谱技术在含水率检测方面研究现状	3
1.3 研究内容	5
1.4 论文结构安排	6
第 2 章 近红外光谱技术原理和数据采集	7
2.1 引言	7
2.2 近红外光谱技术原理	7
2.2.1 近红外漫反射光谱基本原理	8
2.2.2 近红外定量技术基本流程	9
2.3 样本的采集与制备	10
2.4 实验数据采集	11
2.4.1 近红外光谱采集	11
2.4.2 样本含水率采集	12
2.5 奇异样本识别与剔除	13
2.5.1 蒙特卡洛交叉验证法	14
2.5.2 二次检验	15
2.6 本章小结	18
第 3 章 光谱数据的样本划分及预处理	19
3.1 引言	19
3.2 校正集划分	19

3.3 绿茶近红外光谱预处理方法研究	20
3.3.1 多元散射校正	20
3.3.2 标准正态变换	21
3.3.3 Savitzky-Golay 平滑	22
3.3.4 离散小波变换	22
3.3.5 一阶导数	24
3.3.6 二阶导数	24
3.3.7 去趋势	25
3.4 建模方法和评价指标	26
3.5 预处理结果与分析	27
3.6 本章小结	28
第 4 章 特征波长提取方法及建模结果对比	29
4.1 引言	29
4.2 特征波长提取	29
4.2.1 主成分分析	29
4.2.2 竞争性自适应重加权采样	30
4.2.3 连续投影算法	32
4.3 建模方法	33
4.3.1 支持向量回归	33
4.3.2 BP 神经网络	34
4.4 特征波长建模结果对比	36
4.4.1 特征波长建模结果	36
4.4.2 三种特征波长提取方法对比	38
4.5 本章小结	39
第 5 章 基于改进 Stacking 预测模型的建立	40
5.1 引言	40
5.2 集成学习理论概述	41
5.2.1 随机森林	41
5.2.2 自适应提升算法	42
5.2.3 Stacking 集成学习	43
5.3 改进 Stacking 集成学习算法	44
5.4 基学习器改进	45
5.4.1 自适应概率遗传算法	45

5.4.2	基学习器超参数寻优	48
5.4.3	Kendall 相关性分析	50
5.5	模型建立与验证	52
5.5.1	验证 Kendall 相关性分析在基学习器选择的有效性.....	52
5.5.2	改进 Stacking 集成学习的预测结果对比	53
5.6	本章小结	55
第 6 章	总结与展望	56
6.1	总结	56
6.2	研究与展望	57
参考文献		58
攻读学位期间主要的研究成果		64
致 谢		65

第 1 章 绪论

1.1 研究背景与意义

茶叶是中国传统饮品，被超过 160 个国家和地区所饮用^[1, 2]。茶叶中富含有益物质，茶多酚是其中的关键成分，具备抗氧化、抗衰老、抗癌、降低心血管疾病风险等健康功效^[3, 4]。此外，茶叶中还含有咖啡因、氨基酸、维生素和矿物质等成分，可提升免疫力、促进新陈代谢、改善皮肤质量^[5]。茶叶是我国的重要经济作物，近 10 年来，中国茶叶产量持续增长。根据国家统计局和中国海关的数据，2022 年我国茶叶总产量达到 335 万吨，同比增长 5.88%，绿茶产量和消费量占比超过 50%^[6]。绿茶在海外出口方面占据显著优势，出口量占茶叶总出口量的 83.67%，出口额占茶叶总出口额的 66.95%。我国的绿茶产地广泛分布，包括杭州、苏州、湖州和安吉等地，绿茶种类繁多，碧螺春、西湖龙井和信阳毛尖等特色绿茶品种享有全球声誉^[7]。

随着社会进步和人们生活水平的提高，消费者越来越关注绿茶的品质^[8]。绿茶的品质受到多种因素的影响，如绿茶品种、生长地区、加工工艺和贮存方式，其中加工工艺是影响绿茶品质的关键因素，对绿茶的化学成分、外观、香气和口感等方面具有重要影响^[9, 10]。加工工艺的目的是通过脱水、杀青等操作最大限度地保留鲜叶中的水分、酶类及其他活性物质，以形成独特的香气、口感和色泽。加工工艺中的杀青温度、杀青时间、揉捻程度、干燥时间和温度等参数对绿茶品质有重要影响^[11]。杀青温度和时间过高或过长会导致茶叶过度氧化失去鲜爽口感，过低或不足则会导致质量差、口感苦涩。揉捻程度不足会导致形状不佳，过度则会使茶叶变形、损伤。干燥时间和温度过高或过长会使茶叶中的化学成分遭受过度热化和分解，导致茶叶质量下降。过低或不足则会导致绿茶含水率过高，易产生霉变、变质等问题，同时也会影响绿茶的香气、口感和色泽。因此，研究如何根据加工中绿茶的状态来自动调节参数有助于提高绿茶品质和加工效率。

研究发现，含水率能够反映加工中茶叶的状态，是茶叶加工中的关键因素^[12-14]。目前检测加工中的含水率主要使用传统检测方法。传统检测方法主要依靠人工经验或直接干燥法，人工经验法虽然快速，但容易受到人为因素影响导致品质不稳定；而直接干燥法虽准确性高，但测量时间过长导致含水率无法及时反馈给加工设备，可能对茶叶的品质和口感造成影响。因此，为确保绿茶的加工质量，需要探索一种快速准确的含水率检测方法，以便实时调整加工参数。

近红外光谱技术 (Near-Infrared Spectroscopy, NIRS) 是一种基于分子振动引起的光谱吸收现象的重要分析技术，具有非侵入性、快速、高效、无需样品预处理

理等优点^[15]。该技术在化工、医药、农业、饲料等领域广泛应用，能够快速、精准地分析和检测物质的成分和含量^[16-19]。在茶叶领域，NIRS 被广泛用于质量检测，可以测定茶叶中咖啡因、茶多酚、氨基酸等成分的含量，并获取茶叶的发酵程度和产地等信息^[20-22]。因此，通过使用 NIRS 检测加工中的绿茶含水率，可以准确掌握绿茶的加工状态，进而调控加工装置参数，提升绿茶的品质和口感，实现绿茶质量的监控和加工效率的提高^[23]。

1.2 研究现状

1.2.1 绿茶含水率检测研究现状

根据检测原理的不同，绿茶含水率测定法可分为直接测定法和间接测定法，如图1-1所示。直接测定法是通过加热或干燥步骤处理茶叶样品，或观察茶叶的外在特征，直接计算出含水率。而间接测定法则是利用与茶叶含水率相关的物理性质或化学性质建立数学模型，从而间接推断含水率。




图 1-1 绿茶含水率主要检测方法

直接测定法包括人工经验法和直接干燥法。人工经验法通过观察茶叶的外在特征来判断茶叶的含水率，检测方式方便快捷，适用于一些小规模或简单的生产场合^[24]。但该方法测定精度较低且受人为因素影响较大。直接干燥法则是利用绿茶样品中水分的蒸发来测定含水率，测量准确但测量时长超过两小时^[25]。而快速水分测定仪是利用直接干燥法进行测定，并结合了称重传感器和环形辐射源，可快速均匀地干燥样品并测量样品的丢失重量，最终计算出样品的水分含量^[26, 27]。该方法与直接干燥法具有良好的一致性，但其检测效率高于直接干燥法，通常只需要 3 到 15 分钟即可完成。

在茶叶含水率检测领域，目前常用的间接测定方法包括核磁共振法、电容

法、微波法和近红外光谱技术等。核磁共振法利用外磁场的强度和频率来测量样品中的水分含量,但由于仪器设备昂贵、需要专业人员操作,在茶叶领域的应用受到限制^[28,29]。电容法是一种通过测量物质在不同含水率下的电容值变化来确定物质含水率的方法。然而,该方法容易受到外界温度、湿度、电场强度等因素的影响,且不适用于含水率较低的情况^[30,31]。微波是频率在 300 MHz-300 GHz 之间的电磁波,具有强大的穿透能力。茶叶中的水分含量可以通过检测微波电场强度的变化来反映^[32]。微波测量技术具有快速和非侵入性等优点,适用于茶叶含水率的快速实时检测^[33]。然而,该技术对物质中的参杂物和杂质敏感,测量误差较大,且设备成本高,使用和维护较为困难,在茶叶含水率检测中应用较少。

近红外光谱技术是一种基于分子振动引起的光谱吸收现象的分析技术^[34]。它利用样品对近红外光的吸收特征来获取茶叶中水分含量的信息。通过采集样品在近红外漫反射光谱,分析样品中水分分子对光的吸收程度,从而推断样品的含水率。近红外光谱技术具有非侵入性、快速和高效的特点,因此被广泛应用于含水率的检测和分析。

1.2.2 近红外光谱技术在含水率检测方面研究现状

近红外光谱技术被广泛应用于各个领域的含水率测量,例如农业、食品、药材、纺织品等。Liang 等^[35]对杨树木屑的含水率和基本密度进行了检测。研究通过光谱预处理技术提高了预测模型的准确性和稳健性,并在完全独立的样本集中,表现出了在含水率和基本密度预测方面的可接受性。调查结果显示,在含有游离水的细胞腔内时,水分分子的宽吸收带与木材性质相关的有用信号部分重叠,会影响光谱特征和基本密度之间的校准关系。并且发现保持木片在低而均匀的含水状态下,有助于获得可靠的木材密度估计值。Amir Malvandi 等^[36]使用便携式近红外光谱(NIRS)结合多元分析方法,实现对苹果片在直接接触超声波干燥过程中水分含量的实时评估。研究开发了 PLSR 和高斯过程回归(GPR)模型,并通过内部交叉验证和外部数据集评估了不同预处理方法和数据分区算法的性能。通过 SPA 选择了三个波长(1359、1517 和 1594 nm),并使用这些波长建立了一个闭式方程来预测水分含量, $R_p^2 = 0.99$, RMSEP = 3.32%。结果表明,便携式 NIRS 结合多元分析方法非常有前途,可用于监测和评估超声波干燥过程中的水分含量。Muhammad Makky 等^[37]采用 1000-2500nm 短波红外光谱,通过非破坏性评估方法快速确定了苏门答腊西部两种本地水稻品种(Junjuangan 和 Mundam)的含水率。实验中将具有相同含水率的稻谷样品放入 10cm 培养皿中,并使用 SWIR 分光光度计进行测量。通过主成分分析(PCA)处理谷物的光谱数据,并通过偏最小二乘(PLS)方法与其含水率相关联。结果表明,通过光谱分析

的非破坏性评估可以精确确定稻谷的含水率，其中 Junjuangan 和 Mundam 大米的相关性分别为 0.826 和 0.955，均方根误差校准 (RMSEC) 分别为 2.97 和 1.4，模型验证产生的相关性分别为 0.788 和 0.968，RMSEP 分别为 3.8 和 1.29，偏差分别为 0.193 和 0.171。

目前许多国内外学者已经基于近红外光谱技术的茶叶含水率快速无损检测进行了大量研究。陈琳等^[38] 采用联合区间偏最小二乘法 (siPLS) 实现了快速无损检测工夫红茶干燥中的含水率，结果表明，siPLS 模型可以进一步提高水分预测模型的精度，siPLS 筛选建模区间与水分子中 O-H 键在近红外光谱 1100 nm、1400 nm、1600 nm 处的吸收峰呈现一定的相关性，为 siPLS 建模的良好效果提供了理论支撑。李晓丽等^[39] 使用可见-短波近红外光谱仪对 568 个茶叶样本进行光谱扫描，采用小波变换提取特征信息，比较三种回归算法结果，发现 SVR 模型表现最优，建模和预测相关系数分别为 0.9985 和 0.9875。胡永光等^[40] 研究了绿茶加工过程中难以快速无损检测杀青叶料含水率的问题，提出了一种基于可见-近红外光谱分析的方法。该方法在 350~2500 nm 波段范围内获取茶叶杀青叶料的漫反射光谱信息，并通过预处理方法提取出 5 个主成分，建立了 PLSR 模型。结果表明，该方法可以准确地预测绿茶杀青叶料的含水率，预测相关系数为 0.819，均方根误差为 0.037，平均相对误差为 3.30%。该方法为绿茶含水率的快速无损检测提供了一种有效的解决方案。Zhang 等^[41] 针对传统的含水率检测方法耗时且破坏性强的问题，将离散小波变换 (DWT) 与自举软收缩算法 (BOSS) 相结合，以消除光谱数据中的干扰变量。通过将光谱分解成六个子层，DWT 消除了光谱中的噪声。BOSS 通过减少子层重构光谱的维度来选择有效的变量。在 DWT 和 BOSS 选择有效变量后，基于 PLS 建立预测模型。通过与全谱 PLS、遗传算法 PLS (GA-PLS) 和区间 PLS (iPLS) 进行比较，验证了预测模型的有效性和稳定性，有望应用于预测英红九号茶叶中的含水率。Huang 等^[12] 采用九个批次来自三个品种的茶叶样品验证了模型转移在改善光谱模型泛化能力方面的表现。通过模型转移，成功消除了不同品种和批次之间的光谱差异，提高了 PLSR 模型的预测能力。该研究表明，通过纠正光谱数据的模型转移策略可以成为不同类型茶叶含水率快速检测的强大技术，并为工业应用奠定基础。Shen 等^[42] 实现了一种快速检测茶叶萎凋过程中含水量的计算系统，以实现茶叶工业数字化。研究采用了微型-近红外光谱技术 (micro-NIRS) 和 Elman 神经网络 (ENN) 相结合的方法，设计了一种基于 ENN 的含水量预测模型。该模型结合了主成分分析 (PCA)，能够快速检测和分析萎凋叶片的含水量。

尽管不同茶叶品种的含水率预测模型存在差异，但所使用的理论方法具有一定的普适性。随着化学计量学的发展，近红外光谱技术中的光谱数据分析、处

理方法得到了优化和改进,尤其在光谱数据预处理、特征波长选择和预测模型建立方面取得了进展。然而,在实际工业生产中,目前仍面临一些问题,包括模型预测精度不高以及模型的稳定性和泛化能力的不足。本文的研究旨在提高加工中含水率检测的可靠性和实用性,通过特征波长提取方法和集成学习算法来提高回归模型的预测精度和泛化能力。

1.3 研究内容

本文的研究内容是基于近红外光谱技术检测加工中的绿茶含水率,具体为:

(1) 研究了实验方案和近红外光谱数据采集方案。包括光谱数据的获取过程和绿茶含水率的测定方法。考虑到实验操作失误、仪器误差或样品污染等因素可能导致奇异样本的出现,采用了蒙特卡洛交叉验证(MCCV)方法和二次检验来剔除奇异样本,以确保后续研究的数据质量。

(2) 研究了光谱数据的样本划分及预处理。采用 SPXY 方法对数据进行划分,得到校正集和预测集。然后应用多元散射校正(MSC)、标准正态变换(SNV)、Savitzky-Golay 平滑(SG 平滑)、离散小波变换(DWT)、一阶导数(FD)、一阶导数(SD)和去趋势(DT)等方法进行预处理,选择出最适合的预处理方法。

(3) 研究了特征波长提取算法及回归模型。对于原始光谱会存在大量冗余信息和干扰信息,会影响预测模型的准确性,本文研究了主成分分析(PCA)、竞争性自适应重采样加权算法(CARS)和连续投影算法(SPA)这三种方法的原理。然后使用这三种方法提取特征波长,并建立了偏最小二乘回归(PLSR)、支持向量回归(SVR)和 BP 神经网络(BPNN)这三种回归模型。最后对不同特征波长提取方法和回归模型的结果进行了比较,选择适当的波长选择方法和回归模型,可以减少冗余变量的干扰,从而提高含水率预测模型的准确性。

(4) 研究了基于改进 Stacking 含水率预测模型的建立。针对单一模型容易出现不稳定、泛化能力不足的问题,改进了 Stacking 中的基学习器组合的选取和基学习器本身的性能。在基学习器组合的选取方面,采用 Kindall 相关性分析筛选独立性强的模型作为基学习器,并建立多种组合的 Stacking 集成学习。通过与多种组合的 Stacking 集成学习进行比较,验证了 Kindall 相关性分析的可行性和有效性。在基学习器的性能方面,采用自适应遗传算法对基学习器的超参数进行优化,以提高改进 Stacking 的预测性能。最终对基学习器和改进 Stacking 的性能进行比较,并通过实验验证了改进 Stacking 在绿茶含水率检测模型的有效性,构建了泛化能力更强、模型更稳定的绿茶含水率检测模型。

1.4 论文结构安排

全文内容共六章，具体内容组织如下：

第一章说明了本研究的目的与意义，介绍了目前国内绿茶含水率检测现状，阐述了基于近红外光谱技术检测含水率的国内外发展及研究现状，总结了本文的研究内容。

第二章阐述了近红外光谱的基本原理和分析技术的基本流程，介绍了制备绿茶样本、采集近红外光谱数据以及含水率测定的过程，剔除了绿茶数据的奇异样本。

第三章介绍了光谱数据的样本划分及预处理，采用 SPXY 方法进行划分校正集和预测集，使用 MSC、SNV、SG 平滑、DWT、FD、SD 和 DT 共七种方法进行光谱预处理，分别建立 PLSR 模型，筛选最优的预处理方法。

第四章介绍了特征波长提取方法及建模结果的比较。首先介绍了 PCA、CARS、SPA 这三种方法的原理。然后使用这三种方法提取特征波长，分别建立了 PLSR、SVR 和 BPNN 这三种回归模型。根据回归模型的评价指标，对不同特征波长提取方法进行了比较，以选出最优的特征波长提取方法和回归模型。

第五章介绍了基于 Stacking 集成学习的绿茶含水率检测模型。针对单一模型存在的不稳定性和泛化能力不足的问题，提出了一种改进的 Stacking 集成学习方法应用于绿茶含水率检测。通过 Kindall 相关性分析选择了独立性强的模型作为基学习器，并验证了改进的 Stacking 集成学习的有效性。为了提升基学习器的预测性能，针对模型超参数的重要影响，提出了一种自适应遗传算法进行超参数优化。该优化方法显著提高了基学习器的预测性能，进一步提升了改进的 Stacking 集成学习的整体预测性能，为绿茶含水率检测提供了一种新的技术实现。

第六章为总结与展望，对全文的研究内容进行总结，分析了实验中存在的问题，并提出了未来进一步的展望。

第2章 近红外光谱技术原理和数据采集

2.1 引言

为了研究基于近红外光谱技术的绿茶含水率预测模型，需要了解近红外光谱的基本原理。近红外光谱主要反映了含氢基团的原子振动倍频和合频吸收，这些振动的频率和强度可以提供关于分子的结构、化学键和分子量等信息，可用于测量有机物的各种属性信息，如含水率、化学成分、含量等。在近红外定量分析流程中，包括预处理、特征波长提取和回归建模等步骤，通过这个过程可以将光谱数据与样本属性之间建立关系。而在建立预测模型之前，首先需要进行以下步骤：制备符合国家标准的绿茶样本，采集绿茶表面的近红外反射光谱，并进行绿茶含水率的真实值测定。这些步骤为后续的预测模型建立提供必要的数据库。在近红外光谱回归建模中，样本数据的质量对建模结果的准确性至关重要，然而实验操作失误、仪器误差或样品污染等因素可能导致奇异样本的出现。本文将使用蒙特卡洛交叉验证法和二次检验对奇异样本进行识别和剔除，以此提高样本数据的准确性和鲁棒性，为后续建立预测模型提供基础。

2.2 近红外光谱技术原理

近红外光谱技术 (Near-infrared Spectroscopy, NIRS) 是一种基于分子振动引起的光谱吸收现象的方法。该技术使用介于可见光 (VIS) 和中红外光 (MIR) 之间的电磁波，即近红外光 (NIR)，其中又分为短波 (SW-NIR) 和长波 (LW-NIR) 两个区域。近红外光的波长范围在 780-2526nm 之间，如图2-1所示。在近红外光谱的波长范围内，可以探测到样本中主要的内含物，如氨基酸、有机物和水等的光谱信号，通过记录和分析这些信号可以获取样本的物理和化学信息。




图 2-1 近红外光的波长示意图

近红外光谱通过照射光线到样品表面，含氢基团的原子振动倍频和合频吸收或其他化学物质的分子振动会导致吸收光的能量发生变化，这些振动的频率和强度可以提供关于分子的结构、化学键和分子量等信息，可用于测量有机物的

各种属性信息，如含水率、化学成分、物质含量等^[43, 44]。使用近红外光谱技术结合化学计量学对这些光谱信息进行分析和处理，建立与含水率相关的预测模型，可以实现对绿茶含水率的快速预测。

2.2.1 近红外漫反射光谱基本原理

近红外光谱技术的基础是朗伯-比尔（Lambert-Beer）定律，它描述的是一个透射现象，即当一束单色光通过透明介质时，透射光的强度与初始光的强度之间存在一定关系。图2-2为透射光谱示意图，初始光照强度（ I ）和透射光照强度（ I_0 ）的关系如公式2-1所示。

$$I = I_0 \exp[-\alpha(v)CL] \quad (2-1)$$

式中： $\alpha(v)$ 为介质的光谱吸收系数， L 为光程吸收长度，即光在介质中的传输长度， C 为介质浓度。




图 2-2 透射光谱示意图

绿茶中的固态和液态成分具有不同的折射率和吸收特性，且固体颗粒相对较大，因此无法将其视为均匀的溶液。传统的朗博-比尔定律在绿茶含水率测量中无法保证准确性和可靠性。为了解决这个问题，本文采用漫反射光谱来检测绿茶含水率。

漫反射光谱是利用特定波长和强度的光源照射样品，并分析反射光来获取样品表面和内部的物理化学性质。其基础理论是 Kubelka-Munk 理论，相较于 Lambert-Beer 定律，它更能准确描述散射介质中的光学过程，并更好地反映样品表面的物理化学性质^[45]。

在绿茶加工生产中，可以通过传送带采集绿茶样本的漫反射光谱。图2-3展示了绿茶样本漫反射光谱的采集示意图。光谱采集过程中，近红外光线由光源照射到待测样本表面，漫反射检测器（如近红外光谱仪）获取漫反射光。采集软件用于保存漫反射吸光度光谱。漫反射吸光度可通过 Kubelka-Munk 定理计算，其

相对漫反射率 R 和吸光度 A 的计算如公式2-2和2-3所示^[46]。

$$R = \frac{I_1}{I_2} \quad (2-2)$$

$$A = \lg \left(\frac{1}{R} \right) \quad (2-3)$$

式中： I_1 为待测样品的漫反射的光强度， I_2 为标准白板的漫反射的光强度，标准白板是一块具有高反射率（一般 $R > 95\%$ ）的白色表面固体。




图 2-3 绿茶样本的漫反射光谱采集示意图

2.2.2 近红外定量技术基本流程

图2-4展示了近红外光谱定量技术的基本流程。光谱数据采集后，基本流程包括以下六个步骤：1. 对奇异样本进行识别与剔除；2. 将光谱数据划分为校正集和预测集，其中校正集用于建立预测模型，预测集用于验证模型效果；3. 对光谱数据进行预处理包括去噪、平滑等操作；4. 特征波长提取，选择具有预测能力的特征波长，以提高建模的准确性和降低数据复杂性；5. 基于校正集的光谱数据和真实属性值，建立回归模型，并使用预测集的数据进行预测；6. 使用评价指标对模型的预测能力和准确性进行评估。

由于实验操作失误、仪器误差或样品污染等因素，实验数据中常常存在异常数据。这些异常数据即奇异样本会破坏光谱和真实值之间的对应关系，并且改变样本集的统计特性，从而降低模型的预测精度和稳定性，因此需要进行奇异样本的识别与剔除。

预处理是近红外光谱技术中非常重要的一步，它可以消除光谱中的噪声、提高光谱的信噪比，从而减少误差并提高模型的准确性。预处理方法主要有标准正态变量转换、平滑法、归一化等。预处理的方法需根据不同的分析目的、作用和数据特点进行选择，从而获得更加准确和可靠的光谱数据，提高光谱分析的精度和效率。

在建模前，通常需要对光谱进行降维或特征提取，以提高建模的准确性和预测性能。特征波长指的是在光谱数据中具有明显特征和预测能力的波长点，对建

立光谱预测模型至关重要。在近红外光谱数据中，物质的化学键和振动转动通常在特定波长范围内产生吸收峰，这些吸收峰即为特征波长。特征波长能够提取样本中重要信息，去除噪声和干扰，提升光谱预测模型的准确性和可靠性。常见的特征波长提取方法包括主成分分析、连续投影算法和竞争自适应重采样加权算法。通过提取与待测属性相关的特征波长，可以建立模型复杂度更低的预测模型。

对光谱进行预处理和特征波长提取后，可以采用回归方法建立光谱和样本属性之间的关系模型，可以简单描述为：

$$y = f(X) \quad (2-4)$$

式中： X 为 $N \times M$ 的光谱矩阵， y 表示样本属性， f 表示线性或非线性的函数关系。

关系模型在预测集上进行预测，使用评价指标（如决定系数 R^2 、均方根误差 $RMSE$ ）对模型的预测性能进行评估。




图 2-4 近红外光谱定量技术的基本流程

2.3 样本的采集与制备

绿茶是一种非发酵茶，经过杀青、揉捻和干燥等工艺制成。作为中国传统的茶叶之一，绿茶具有悠久的历史 and 广泛的普及度。绿茶的生长和生产需要特定的环境条件，如适宜的气候、土壤和水源等。一般而言，绿茶适宜的生长温度为 10-30 摄氏度，降水量在 1000-2000 毫米之间，土壤要求肥沃且透气性良好。绿茶具有翠绿的色泽、清香幽雅的香气以及鲜爽的味道，深受广大消费者的喜爱，是中华优秀传统文化中不可或缺的一部分。

本研究以毛尖绿茶为样本进行研究。样本于 2021 年 7 月 14 日在湖南省长沙县金井镇采集，采集工作在湖南省湘丰茶业有限公司进行。金井镇位于湖南省中南部，地势崎岖，气候温和湿润，雨水和阳光充足，适宜茶树生长。采集实验在上午 10 点在茶园进行，共采摘了 10 公斤的新鲜绿茶叶，包括单芽、一芽一叶、一芽两叶，叶片长度为 3 至 4 厘米。

2.4 实验数据采集

2.4.1 近红外光谱采集

本实验在室温约为 22℃、相对湿度约为 65% 的环境下进行。绿茶的加工步骤包括鲜叶、萎凋、杀青、冷却回潮、揉捻、干燥 1 和干燥 2，共计七个步骤。在该实验中，新鲜的绿茶样本经过上述步骤进行加工处理，每个时序采集一定数量的样本。其中，鲜叶是指采摘的新鲜绿茶样本；萎凋是指将绿茶样本在凉爽、通风环境下均匀散晒 7 小时，使茶叶均匀柔软，有利于后续的加工处理；杀青采用 6CST-70 滚筒式杀青机（长沙湘丰智能装备有限公司）进行处理，杀青机转动速度为 24r/min，加热温度分别为 340℃/320℃/300℃，时间为 5 分钟，使绿茶中的酶类失活，防止其氧化。冷却回潮采用转速为 28r/min 的风扇进行冷却风干，使茶叶缓慢地冷却回潮，恢复弹性质地。揉捻采用 6CR-55 卷曲机（长沙湘丰茶叶机械制造有限公司）进行处理，持续 30 分钟，旨在使茶叶形态和香味符合要求。干燥 1 和干燥 2 分别使用 6CHBZ-20 干燥机（长沙湘丰茶叶机械制造有限公司）对茶叶进行两次干燥处理，干燥 1 温度设定为 120℃，叶片长度为 1~2 cm，时间为 25 分钟；干燥 2 温度设定为 95℃，叶片长度为 1 cm，时间为 30 分钟。

为了采集绿茶的近红外光谱，需要使用光源、光纤、近红外光谱和标准白板等设备，主要采集设备如图 2-5 所示。在本次实验中，选取经过加工处理后自然降温至室温的绿茶样本进行光谱采集，采用厦门 AOPTICS 公司的 ATP8600 微型光纤光谱仪，波长范围为 920 到 1692nm，分辨率为 3nm，共有 256 个波长。光源采用美国 Ocean Optics 公司的 HL2000-HP-FHSA，功率为 7W，寿命为 1500 小时，距离标准白板 30 厘米，采集设备以 45 度角距离白板 40 厘米。在实验前，光源预热 5 分钟，光谱仪预热 30 分钟，防止不稳定现象的发生，确保采集稳定状态下的光谱，减小仪器噪音。标准白板的长和宽均为 8cm，取 20 克样品均匀放置在标准白板上，厚度约为 3~5cm，每个样品采集三次光谱，取平均值作为样品的原始漫反射强度光谱。采集过程中，标准白板的反射强度和暗电流信号每隔 30 分钟采集一次，以减小背景信号和暗电流的影响。最后，根据漫反射定律，将原始反射强度光谱转化为漫反射吸收光谱 A ，如公式 2-5。

$$A = \lg \left(\frac{1}{R} \right) = \lg \left(\frac{I_0 - I_1}{I_2 - I_1} \right) \quad (2-5)$$

式中： R 表示漫反射反射率光谱， I_0 表示原始反射光强度， I_1 表示暗电流信号的反射光强度， I_2 表示标准白板的反射光强度。

本实验共收集了 462 个光谱数据，用于建立检测绿茶加工过程中的水分含量模型。其中，鲜叶过程收集了 84 个光谱数据，萎凋过程收集了 84 个光谱数据，



图 2-5 主要采集设备

杀青过程收集了 71 个光谱数据，冷却回潮过程收集了 59 个光谱数据，干燥 1 过程收集了 59 个光谱数据，干燥 2 步骤收集了 53 个光谱数据。这 462 个样本的原始漫反射吸收光谱如图2-6所示。




图 2-6 原始漫反射吸收光谱

图2-7显示了绿茶加工过程中各步骤的平均吸收光谱。观察平均光谱发现，鲜叶步骤的样本在 1300~1500nm 范围内的吸收度较高，推测是由于含水率较高，导致水的 OH 基团的一阶频率加倍的拉伸振动造成的。而 1200 nm 和 1450 nm 处的吸收谷则可能由水的 OH 键引起，这是水的主要特征基团^[47]。在干燥 2 过程中，光谱在 1000 nm 至 1200 nm 范围内明显降低，可能是由于绿茶的含水量减少、绿茶多酚等干物质增加以及样本颜色的变化所致。因此，可以发现不同加工步骤的光谱存在差异，验证了近红外光谱技术检测绿茶含水率的可行性。

2.4.2 样本含水率采集

在光谱采集后，对样本进行了含水率测定，采用了国家标准 GB5009.3-2016。测量使用了 XYSKALE 分析电子称量天平和 BOWELL 烤箱。含水率的测量步骤




图 2-7 绿茶加工中的每个步骤的平均光谱

包括：先称量样品质量 M_0 ，然后将样品放入玻璃制的扁形称量瓶中，称量二者总质量 M_1 ，在 $101^{\circ}\text{C}\sim 105^{\circ}\text{C}$ 的干燥箱中加热 2 小时，取出并加盖，放入干燥器中冷却 0.5 小时，再次称量，反复操作直至前后两次质量差不超过 2mg 。最后，取前后两次恒重值中的较小值作为加热后的总质量 M_2 ，计算每个样品的水分含量 M_C 如公式 2-6 所示。

$$M_C = \frac{M_1 - M_2}{M_0} \times 100\% \quad (2-6)$$

每个加工步骤中的绿茶样品的含水率信息如表 2-1 所示。

表 2-1 每个加工步骤中的绿茶样品的含水率信息

加工步骤	范围 (%)	平均值 (%)	方差 (%)	样本数
鲜叶	74.11~78.74	75.94	0.75	84
萎凋	65.0~72.69	68.26	0.53	84
杀青	48.43~54.69	50.42	0.90	71
冷却回潮	44.98~50.43	46.71	0.63	59
揉捻	46.86~52.13	48.36	0.81	68
干燥 1	31.13~35.67	32.94	0.47	53
干燥 2	8.17~10.94	9.28	0.34	43

2.5 奇异样本识别与剔除

在近红外光谱建模中，样本质量对结果准确性至关重要。异常数据是由实验操作失误、仪器误差或样品污染等因素引起的。这些异常数据会破坏光谱与真实值之间的对应关系，改变样本集的统计特性，降低模型的预测精度和稳定性。由

于不同实验者或实验环境下，奇异样本可能不同，导致数据的重复性和可比性降低，分析结果不可比。因此，在近红外光谱建模中，识别和剔除奇异样本至关重要，以提高数据质量和可靠性，从而使预测模型更准确和稳定。

2.5.1 蒙特卡洛交叉验证法

Konovalov 等^[48]提出了一种基于蒙特卡洛交叉验证 (Monte Carlo cross validation, MCCV) 的奇异样本识别方法。蒙特卡洛法是一种基于概率统计理论的数值计算方法，它利用随机抽样和统计模拟的思想来解决问题。蒙特卡洛法的基本原理是通过大量的随机实验来估计事件的概率或随机变量的数学期望值。蒙特卡洛法的灵活性使其适用于各种类型的问题，特别是那些难以通过解析方法求解的复杂问题。由于 PLSR 模型对于奇异样本具有很高的敏感性，其预测性能对于正常样本和奇异样本的性质存在较大差异。当校正集中存在奇异样本时，PLSR 模型的预测性能会受到影响。

因此，本文结合蒙特卡洛法和 PLSR 模型来识别奇异样本，并使用交叉验证法确定合适的 PLSR 主成分数。图2-8为 MCCV 方法检测奇异样本的流程图，本文的具体识别步骤如下：

- (1) 采用 5 折交叉验证法的 RMSECV 确定 PLSR 模型的最佳主因子数。
- (2) 随机取样将校正集样本分成两部分，随机选择 80% 的样本用于训练集，余下的 20% 则作为测试集，并建立 PLSR 模型用于训练和预测。
- (3) 步骤 2 重复 N 次，通常选择 $N \geq 1000$ ，以确保每个样本都能获得自己的预测残差序列。
- (4) 计算出每个样本的预测残差的均值 $\bar{e}_j$ 和方差 s_j ，超过设定的 $\bar{e}_j$ 阈值和 s_j 阈值可疑奇异样本。本文中 $\bar{e}_j$ 阈值 $T_m = \text{mean}(\bar{e}_i) + 2 \text{std}(\bar{e}_i)$ 和 s_j 阈值 $T_s = \text{mean}(s_i) + 2 \text{std}(s_i)$ 。




图 2-8 MCCV 方法检测奇异样本的流程图

使用上述步骤进行奇异样本识别，其中 $N=1000$ ，PLSR 模型的最佳主成分确定为 17。图2-9展示了 MCCV 的残差均值-方差图， T_m 为 5.34， T_s 为 1.67。从图2-9可知，利用 MCCV 的 MEAN-STD 法初步判为奇异样本的有第 3、94、96、138、173、207、235、241、246、255、265、273、282、292、316、373、428、438 号个可疑奇异样本，均在右下角，其样本偏差均值 $\bar{e}_j$ 偏离大多数样本。

2.5.2 二次检验

上节采用了 MCCV 方法来筛选奇异样本，然而有时会发生偶然情况，导致正常样本被错误地判断为奇异样本，因此需要对可疑奇异样本进行二次检验。图2-10展示了 MCCV 二次检验的流程。假设有 m 个可疑奇异样本点，随机删除一个样本后建立 PLSR 模型得到 $RMSEP_j$ ，重复上述步骤 n 次，以得到平均 $RMSEP_\mu$ 。随机删除一个可疑奇异样本建立 PLSR 模型得到 $RMSEP_j$ ，如果 $RMSEP_j$ 值大于 $RMSEP_\mu$ ，则说明该可疑奇异样本对 PLSR 模型产生了正向作用，则该样本应该保留在样本集中。反之，如果可疑奇异样本的 $RMSEP_j$ 值小于 $RMSEP_\mu$ ，则说明该可疑奇异样本对建模产生了负面作用，即该奇异样本应该在样本集中剔除。 $RMSEP_\mu$ 通过公式2-7进行计算。

$$RMSEP_\mu = \frac{\sum_{i=1}^N RMSEP_i}{N} \quad (2-7)$$

对上文中的 18 个可疑奇异样本进行了二次检验。图2-11展示了建模次数 N




图 2-9 MCCV 的残差均值-方差图




图 2-10 MCCV 二次检验流程

与 $RMSEP_\mu$ 之间的关系曲线，发现当 N 为 2000 时， $RMSEP_\mu$ 为 1.2881。如果一个可疑样本的预测均方差 $RMSEP_j$ 满足条件 $RMSEP_j < RMSEP_\mu$ ，则判定该样本为奇异样本并将其删除，否则将保留在校正集中作为正常样本。表2-2为 MCCV 检验后的可疑奇异样本的二次检测结果。从表中可知，剔除第 3、94、138、


图 2-11 $RMSEP_{\mu}$ 随建模次数 N 的曲线图

表 2-2 MCCV 可疑奇异样本二次检测

序号	样本编号	$RMSEP_j$ (%)	是否为奇异样本
1	3	1.2893	否
2	94	1.2823	否
3	96	1.2682	是
4	138	1.2879	否
5	173	1.2891	否
6	207	1.2875	否
7	235	1.2946	否
8	241	1.2898	否
9	246	1.2843	是
10	255	1.2835	是
11	265	1.2859	否
12	273	1.2866	否
13	282	1.2748	是
14	292	1.2765	是
15	316	1.2854	否
16	373	1.2965	否
17	428	1.2819	是
18	438	1.2946	否

173、207、235、241、265、273、316、373、438 号样本后，模型效果变差，表明这些样本对模型有正向作用，因此可以将其视为正常样本，并保留在样本数据中。反之，剔除了 96、246、255、282、289、428 号共 6 个可疑样本后的 $RMSEP_j$ 分别为 1.2682、1.2843、1.2835、1.2748、1.2765、1.2819，均小于 1.2881，因此剩余 456 个样本经过二次检测后保留在样本集中，进一步优化了模型效果，并排除了偶然性影响。

2.6 本章小结

本章详细介绍了近红外光谱技术的原理和数据采集过程。在绿茶加工过程中的不同阶段，制备了 462 份样本并进行漫反射测量，真实含水率按照国家标准 GB5009.3-2016 测定。使用 MCCV 识别出 18 个可疑奇异样本。为了排除偶然情况，并采用二次检验对 18 个可疑奇异样本进行验证，剔除了 96、246、255、282、289 和 428 号共 6 个奇异样本。提高了样本数据的准确性和鲁棒性。这为后续使用近红外光谱技术建立绿茶含水率模型提供了可靠的数据基础。

第3章 光谱数据的样本划分及预处理

3.1 引言

经过剔除奇异样本的光谱数据后,为了建立绿茶含水率预测模型,需要将样本数据划分为校正集和预测集。校正集用于回归模型的建模,而预测集则用于评估模型的预测能力。为了确保校正集样本具有代表性和差异性,以保证模型具备良好的预测和泛化能力,本文采用了 SPXY 算法对样本集进行划分。在建立预测模型之前,需要考虑原始光谱在采集过程中受到各种因素的影响,如仪器设备、样品表面的污染和变形以及实验环境等。为了保证建模数据的有效性和可靠性,需要对采集到的光谱数据进行适当的预处理。常用的光谱预处理方法包括标准 SNV、MSC 和 SG 平滑等方法。通过应用 PLSR 方法对经过不同预处理方法处理后的光谱数据进行回归建模,并进行分析和比较,可以确定最佳的预处理方法来建立绿茶含水率预测模型,为后续的特征波长提取和回归预测模型建立奠定基础。

3.2 校正集划分

在建立预测模型之前,划分校正集是绿茶含水率预测模型建立过程中的重要步骤。想要建立一个预测能力强、泛化能力强的预测模型,需要将有代表性和差异性的样本加入校正集,并使用交叉验证进行评估。SPXY 算法是一种用于建立光谱与理化值之间关系的算法^[49]。SPXY 算法的优点在于可以保持绿茶含水率数据的特征和分布情况,减少模型对训练数据的依赖,提高模型的稳定性,并降低对异常值和噪声的敏感性。它通过计算光谱 X 与理化值 Y 之间的联合距离,通过分析 X 和 Y 之间的关系,选择具有较大联合距离的样本作为校正集,将剩余的样本作为预测集,联合距离 $d_{xy}(i, j)$ 计算如公式3-1所示。

$$d_{xy}(i, j) = \frac{d_x(i, j)}{\max_{i, j \in [1, n]} (d_x(i, j))} + \frac{d_y(i, j)}{\max_{i, j \in [1, n]} (d_y(i, j))} \quad (3-1)$$

式中: $d_x(i, j)$ 表示样本 i 和 j 之间光谱的欧氏距离, $d_y(i, j)$ 表示样本 i 和 j 之间被测属性的欧氏距离, n 为样本总数

本文使用 SPXY 算法对绿茶样本集进行了划分,其中校正集和预测集的比例约为 4:1。划分后,校正集包含 364 个样本,预测集包含 92 个样本。划分后的数据集样本信息详见表3-1。从表中可以看出,整个样本集的含水率范围在 8.17% 至 78.74% 之间,且校正集的含水率范围已经覆盖了预测集的含水率范围。采用 SPXY 算法合理地根据光谱矩阵和含水率将样本集划分为校正集和预测集,以进一步提高模型的准确性和泛化能力。

表 3-1 SPXY 算法划分的训练集和预测集的样本信息

数据集	范围 (%)	平均值 (%)	标准差 (%)	样本数
样本集	8.17~78.74	51.47	9.48	456
校正集	8.17~78.74	51.84	9.61	364
预测集	8.87~78.43	50.04	9.07	92

3.3 绿茶近红外光谱预处理方法研究

近红外光谱采集过程中存在多种干扰因素，如光源、仪器设备、样品表面的污染和变形以及实验环境等，导致光谱中出现基线漂移、强信号饱和、仪器漂移、杂散光、气溶胶等噪音，降低了数据的精确性和可靠性^[50]。因此，对光谱进行预处理是必要的，预处理可以去除或减少这些噪音，提高数据的信噪比和质量，从而为后续建立稳定的模型提供更加准确和可靠的数据。

本文对原始光谱数据采用以下七种方法进行预处理，包括多元散射校正 (Multiple Scatter Correction, MSC)、标准正态变换 (Standard Normal Variate Transformation, SNV)、Savitzky-Golay 平滑 (SG 平滑)、离散小波变换 (Discrete Wavelet Transform, DWT)、一阶导数 (First Derivative, FD)、二阶导数 (Second Derivative, SD) 和去趋势 (De-trend, DT) ^[50-53]。

3.3.1 多元散射校正

多元散射校正 (MSC) 用于纠正多元散射对样品光谱造成的影响^[54]。在样品光谱测量中，多元散射是指光线在样品内部发生多次反射和散射，导致测量光谱出现失真和峰形变宽的现象。SNV 使得测量结果更加准确和可靠，提高样品光谱的分辨率、降低峰宽、恢复光谱形态等，从而更好地提取样品的化学和结构信息。其计算步骤如下：

(1) 计算所有样本的平均值 $\bar{X}$ ，如公式3-2所示。

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (3-2)$$

(2) 对所有样本的光谱和平均光谱之间做多元线性拟合，斜率 m_i 和截距 β_i 计算如公式3-3所示。

$$X_i = m_i \bar{X} + \beta_i \quad (3-3)$$

(3) 求得所有样本 MSC 校正后的光谱 $X_{MSC}(i)$ ，如公式3-4所示。

$$X_{MSC}(i) = \frac{X_i - \beta_i}{m_i} \quad (3-4)$$




图 3-1 原始光谱数据 MSC 预处理

使用 MSC 方法对绿茶光谱数据进行预处理，预处理结果如图3-1所示。

3.3.2 标准正态变换

标准正态变换 (SNV) 用于对光谱数据进行归一化和去除光谱偏移的操作，可以有效消除光谱数据中的光谱偏移和尺度差异，使得不同样本之间的光谱可以进行更加准确的比较和分析^[55]。通过标准正态变换，样本的光谱数据可以在各个波长上具有相似的尺度和分布特性，使得光谱数据更具可比性和可解释性。SNV 是对每个样本光谱数据进行标准化，SNV 的主要步骤如下：

(1) 计算每个样本的光谱均值 $\bar{X}_i$ ，如公式3-5所示。

$$\bar{X}_i = \frac{1}{N} \sum_{j=1}^N X_{ij} \quad (3-5)$$

式中： $\bar{X}_i$ 表示第 i 个样本的光谱均值， N 为光谱的波长数， X_{ij} 表示第 i 个样本在第 j 个波长上的光谱值。

(2) 计算每个样本的光谱标准差 s_i ，如公式3-6所示。

$$s_i = \sqrt{\frac{1}{N-1} \sum_{j=1}^N (X_{ij} - \bar{X}_i)^2} \quad (3-6)$$

(3) 对每个样本的每个波长进行标准正态变换，如公式3-7所示。

$$\tilde{X}_{ij} = \frac{X_{ij} - \bar{X}_i}{s_i} \quad (3-7)$$

式中： $\tilde{X}_{ij}$ 表示经过标准正态变换后的第 i 个样本在第 j 个波长上的光谱值。

如图3-2所示是经过 SNV 预处理的绿茶光谱图。可以发现，SNV 和 MSC 的预处理后的光谱轮廓相似，主要原因是 SNV 和 MSC 都可以对光谱数据进行归




图 3-2 原始光谱数据 SNV 预处理

一化处理，消除光谱数据的整体偏移和尺度变化，使得预处理后的光谱轮廓更加一致。

3.3.3 Savitzky-Golay 平滑

Savitzky-Golay 平滑 (SG 平滑) 用于平滑曲线并减小噪声的影响，同时保持曲线的形状和特征，有效避免了信号失真的问题^[56]。它是基于局部加权线性回归的思想，通过对一段连续数据的最小二乘拟合来实现数据的平滑处理。其基本算法步骤如下：

(1) 选择窗口大小：选择窗口大小 n 。

(2) 拟合数据：在窗口中拟合一个多项式函数 $f(x)$ ，用最小二乘法求解系数向量 c ，如公式3-8所示。

$$c = (X^T X)^{-1} X^T Y \quad (3-8)$$

式中： X 是一个 $n \times k$ 的矩阵，包含 k 个不同阶数的多项式函数， Y 是一个 $n \times 1$ 的向量，包含窗口内的数据点。

(3) 计算拟合函数的值：对于窗口中的每个数据点 x_i ，计算估计值 $\hat{y}_i$ ，如公式3-9所示。

$$\hat{y}_i = \sum_{j=0}^k c_j x_i^j \quad (3-9)$$

本文设置 $n = 15, k = 5$ ，经过 SG 平滑预处理的绿茶光谱图如图3-3所示。

3.3.4 离散小波变换

离散小波变换 (DWT) 可以将信号分解成不同频率的小波系数，以及相应的尺度系数^[57]。在离散小波变换中，小波函数被用来作为一组基函数，通过对信号进行小波分解，可以得到不同频率上的小波系数和尺度系数，从而实现信号的频




图 3-3 原始光谱数据 SG 平滑预处理

域分析。离散小波变换具有多尺度分析的特点，它可以对信号进行局部分析，对信号的瞬时特征提取能力较强。其基本算法步骤如下：

(1) 选择小波基：在离散小波变换中，小波基函数是一组正交的基函数，用于对信号进行分解和重构。常用的小波函数有 Haar 小波、Daubechies 小波、Symlets 小波、Coiflets 小波和 Biorthogonal 小波等。

(2) 信号分解：将原始信号分解成不同频率的子带，可以使用多级分解。一般情况下，通过对原始信号进行低通滤波和高通滤波，得到一个近似分量 (approximation component) 和一个细节分量 (detail component)。

(3) 重构：通过逆小波变换将分解后的信号重构为原始信号。

本文小波基函数使用的是 Daubechies6 小波，如图3-4所示是经过 DWT 预处理的绿茶光谱图。




图 3-4 原始光谱数据 DWT 预处理

3.3.5 一阶导数

一阶导数 (FD) 通过求取光谱的差分值, 即相邻两个波长点的光谱强度值之差, 从而得到光谱的一阶导数谱线^[58]。其强调光谱的峰、谷以及吸收带等特征, 并减少其他因素的影响, 从而提高后续分析的准确性。它可以在分析光谱的过程中, 减少背景干扰, 增强谱线的特征, 提高信噪比, 有利于光谱的定量分析。

根据差分公式可知, 光谱的一阶导数是对光谱进行微分运算, 因此它能够对光谱数据中的高频变化进行增强, 而对低频变化进行抑制。具体而言, 本文采用先对光谱进行平滑后进行求导转换, 以减少噪声的影响, 对于给定的光谱数据, 其一阶导数可以通过以下步骤计算得到:

(1) 对原始光谱进行平滑处理, 常用的方法包括 SG 平滑、移动平均平滑等。

(2) 对平滑后的光谱数据进行差分运算, 计算相邻两个波长点之间的光谱强度值之差 $y_i^{(1)}$, 如公式3-10所示。

$$y_i^{(1)} = \frac{y_{i+1} - y_{i-1}}{\Delta\lambda} \quad (3-10)$$

本文使用 SG 平滑进行平滑处理, SG 平滑中窗口大小为 15, 拟合阶数为 5, 如图3-4所示是经过 FD 预处理的绿茶光谱图。




图 3-5 原始光谱数据 FD 预处理

3.3.6 二阶导数

二阶导数 (SD) 对光谱进行两次求导, 一阶导数对光谱中的斜率进行了平滑, 而二阶导数则对一阶导数进行了平滑, 可以增强信号中的高频成分^[59]。其通常用于对光谱数据进行峰的检测和精确定位。相比于一阶导数, 二阶导数能够进一步增强光谱峰的特征, 使得峰之间的区分度更加明显, 有利于对光谱中的峰进行识别和定量分析。对于给定的光谱数据, 其二阶导数可以通过以下步骤计算得到:

- (1) 对原始光谱进行平滑处理，常用的方法包括 SG 平滑、移动平均平滑等。
- (2) 对原始光谱计算二阶导数 y_i'' ，如公式3-11所示。

$$y_i'' = \frac{y_{i+1} - 2y_i + y_{i-1}}{(\Delta x)^2} \quad (3-11)$$

式中： y 为光谱数据， Δx 表示光谱数据的采样间隔。

本文使用 SG 平滑进行平滑处理，SG 平滑中窗口大小为 15，拟合阶数为 5，如图3-4所示是经过 SD 预处理的绿茶光谱图。




图 3-6 原始光谱数据 SD 预处理

3.3.7 去趋势

去趋势 (DT) 通过多项式拟合来近似描述光谱中的趋势变化，并将其从原始光谱数据中减去^[60]。其去除光谱中由仪器漂移、散射等因素引起的连续性变化，使得光谱数据更加稳定和可靠，有利于后续的数据分析和建模。给定一个大小为 $n \times m$ 的原始光谱数据矩阵 X ，其中 N 表示样本数， M 表示变量数。现在假设本文用 p 阶多项式拟合这个变量的趋势，其基本算法步骤如下：

- (1) 使用最小二乘法计算出每个维度上的多项式拟合系数 a ，如公式3-12所示。

$$a = (A^T A)^{-1} A^T X \quad (3-12)$$

- (2) 将其从原始数据 X 中减去得到去趋势后的 Y ，如公式3-13所示。

$$Y = X - Xa^T (aa^T)^{-1} aX^T \quad (3-13)$$

使用 DT 方法对绿茶光谱数据进行预处理，预处理结果如图3-7所示。




图 3-7 原始光谱数据 DT 预处理

3.4 建模方法和评价指标

偏最小二乘法回归 (Partial Least Squares Regression, PLSR) 是一种多元数据分析方法, 旨在建立输入自变量和输出因变量之间的预测模型。该算法综合了主成分分析、典型相关分析和多元线性回归的思想, 能够克服光谱变量之间出现的共线性问题, 在近红外光谱技术中具有较强的稳定性和预测能力^[61]。设 X ($n \times m$) 为吸光度光谱矩阵, Y ($n \times p$) 为绿茶含水率矩阵, 其中 n 为样本数, m 为光谱变量数, p 为因变量的个数。

首先对 X 和 Y 提取主成分 T 和 U , 如公式3-14和3-15所示。

$$X = TP^T + E = \sum_{i=1}^c t_c p_c^T + E \quad (3-14)$$

$$Y = UQ^T + F = \sum_{i=1}^c u_c q_c^T + F \quad (3-15)$$

式中: $T = [t_1 t_2 \dots t_c]_{n \times c}$ 和 $P = [p_1 p_2 \dots p_c]_{m \times c}$ 分别为 X 的得分矩阵和载荷矩阵, $U = [u_1 u_2 \dots u_c]_{n \times c}$ 和 $Q = [q_1 q_2 \dots q_c]_{p \times c}$ 分别为 Y 的得分矩阵和载荷矩阵, $E = [e_1 e_2 \dots e_m]_{n \times m}$ 和 $F = [f_1 f_2 \dots f_p]_{m \times p}$ 分别为 X 和 Y 的残差矩阵。

然后使用 T 线性回归拟合 U , 回归系数 B 计算如公式3-16所示。

$$B = (T^T T)^{-1} T^T U \quad (3-16)$$

在使用训练集 X 进行训练时, 综合公式3-14、3-15和3-16, 计算出 U 、 Q 、 T 、 P 、 B 矩阵, 在使用预测集进行预测时, 通过待预测矩阵 X_p 计算出得分矩阵 T_p , 预测结果 Y_p 的计算如公式3-17所示。

$$Y_p = T_p B Q \quad (3-17)$$

在模型校正和预测过程中, 为了对模型预测效果进行评估, 本文使用 5 折交叉验证决定系数 (R_{CV}^2) 和交叉验证均方根误差 (RMSECV) 作为校正集的评价指标, 同时使用预测集决定系数 (R_P^2)、交叉验证均方根误差 (RMSEP) 和相对标准偏差 (RPD) 作为预测集的评价指标。其中, R_{CV}^2 和 R_P^2 越大, RMSECV 和 RMSEP 越低, 说明模型的预测能力和泛化能力越强。当 RMSECV 和 RMSEP 的值越接近时, 说明该模型的预测能力更加稳定, RPD 值越大, 表示模型的预测能力越强。本文使用表3-2中的不同 RPD 值来评估模型的预测能力^[62]。 R_{CV}^2 、 R_P^2 、RMSECV、RMSEP、RPD 的计算分别如公式3-18、3-19、3-20、3-21和3-23所示。

$$R_{CV}^2 = 1 - \frac{\sum_{i=1}^{n_c} (y_{ci} - \hat{y}_{ci})^2}{\sum_{i=1}^{n_c} (y_{ci} - \bar{y}_c)^2} \quad (3-18)$$

$$R_P^2 = 1 - \frac{\sum_{i=1}^{n_p} (y_{pi} - \hat{y}_{pi})^2}{\sum_{i=1}^{n_p} (y_{pi} - \bar{y}_p)^2} \quad (3-19)$$

$$RMSECV = \sqrt{\frac{1}{n_c} \sum_{i=1}^{n_c} (\hat{y}_{ci} - y_{ci})^2} \quad (3-20)$$

$$RMSEP = \sqrt{\frac{1}{n_p} \sum_{i=1}^{n_p} (\hat{y}_{pi} - y_{pi})^2} \quad (3-21)$$

$$SD = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}} \quad (3-22)$$

$$RPD = \frac{SD}{RMSEP} \quad (3-23)$$

式中: n_c 和 n_p 分别表示校正集和预测集的样本数, $\hat{y}_{ci}$ 和 y_{ci} 分别表示第 i 个样本含水率的预测值和参考值, $\hat{y}_{pi}$ 和 y_{pi} 分别表示第 i 个样本在预测集合中含水率的预测值和参考值, $\bar{y}_{ci}$ 和 $\bar{y}_{pi}$ 分别表示校正集和预测集中样本含水率的平均参考值。

3.5 预处理结果与分析

本文使用了 MSC、SNV、DWT、FD、SD、SG 平滑和 DT 共七种方法对绿茶光谱数据进行预处理, 并建立了全光谱的 PLSR 预测模型。表3-3中展示了各种预处理方法建立的 PLSR 模型的结果。通过评估 PLSR 模型的预测指标, 本研究

表 3-2 不同 RPD 值模型的预测能力

RPD 值	预测能力	模型可接受程度
< 1.5	很差	不可接受
1.5 – 2.0	差	可接受
2.0 – 2.5	中等	可接受
2.5 – 3.0	好	良好
> 3.0	非常好	优秀

发现，所有预处理方法相对于原始光谱模型都提升了预测性能。这表明预处理方法能够有效去除或减少光谱噪声，提高数据的信噪比和质量。其中，DWT、FD 和 SG 平滑方法为表现最佳的三种方法。这三种方法建立的 PLSR 模型具有较高的 R_{CV}^2 和 R_P^2 值。尤其是在使用 SG 平滑方法进行预处理后，当最佳主成分为 11 时，PLSR 模型表现最佳，其 R_{CV}^2 为 0.9710，RMSECV 为 2.14%， R_P^2 为 0.9642，RMSEP 为 2.37%，RPD 为 5.2825。SG 平滑预处理后的光谱具有更平滑的特征，并能有效保留光谱信号，避免信号失真问题，提高数据的信噪比和质量。因此，本文将采用了 SG 平滑作为光谱的预处理方法。

表 3-3 不同预处理后的 PLSR 模型结果

预处理方法	最佳主成分	R_{CV}^2	RMSECV (%)	R_P^2	RMSEP (%)	RPD
原始光谱	9	0.9410	2.93	0.9374	3.13	3.9958
MSC	16	0.9712	2.10	0.9414	3.03	4.1320
SNV	15	0.9720	2.08	0.9463	2.90	4.3145
DWT	13	0.9738	2.04	0.9635	2.39	5.2347
FD	29	0.9677	2.24	0.9416	3.03	4.1368
SD	31	0.9720	2.10	0.9601	2.50	5.0087
SG 平滑	11	0.9710	2.14	0.9642	2.37	5.2825
DT	49	0.9684	2.23	0.9581	2.56	4.8859

3.6 本章小结

本章研究采用 SPXY 算法划分校正集和预测集，针对绿茶光谱中的噪音等干扰因素，使用七种方法对光谱进行预处理，以去除光谱中的噪音干扰。使用建立在预处理后的光谱上的 PLSR 模型来评价预处理方法的效果和优劣，并得出 SG 平滑预处理的效果最佳的结论。因此，选用 SG 平滑预处理方法后的光谱作为后续特征波长提取和预测模型建立的基础。

第4章 特征波长提取方法及建模结果对比

4.1 引言

国内目前缺乏专用的含水率近红外光谱分析仪，只能借助通用型近红外光谱仪获取包含丰富信息的光谱矩阵。然而，这些数据中除了有用的物质组成信息外，还存在仪器电噪声和背景干扰等无用的干扰信号。即使进行预处理，也难以完全消除这些干扰，导致建立的模型计算量大且不稳定。并且含水率只在部分近红外谱区表现出明显吸收特性，其他波长与含水率缺乏相关性，存在波长冗余现象。因此，有必要选择特定的波长作为特征波长，剔除掉冗余信息，以提高检测的针对性和速度。

本章将采用三种方法对经过 SG 平滑预处理后的光谱进行特征波长提取，并建立回归模型，以评估不同特征波长提取方法的效果。鉴于光谱与含水率之间呈现非线性关系，本章使用了线性回归模型（PLSR）以及增加了非线性回归模型（SVR 和 BPNN），以增强模型对光谱的拟合能力。通过对不同模型结果的比较，确定最佳的特征波长提取方法和回归模型，从而实现对绿茶含水率的检测。

4.2 特征波长提取

本文的研究对象是近红外光谱数据，其具有数据量大且波长众多的特点。虽然全光谱能够保持绿茶含水率信息的完整性，但同时也会增强其他茶叶内含物的光谱信息。这种情况下，模型反演速度会降低，可能会影响绿茶含水率反演的精度。因此，对于近红外光谱数据，需要通过特征波长提取方法，选择出最具代表性和区分度的波长，以降低光谱数据的维度，提高预测模型的精度和稳定性^[63]。本文对 SG 平滑预处理后的光谱采用了三种波长选择方法，通过建立三种回归模型来选出预测效果最佳的波长选择算法，接下来将对这三种方法进行介绍。

4.2.1 主成分分析

主成分分析（Principal Component Analysis, PCA）基于协方差矩阵的特征分解理论实现。其核心思想是通过线性变换将原始数据映射到一个新的坐标系，以最大化数据在新坐标系下的方差，从而实现降维的目标^[64]。具体而言，主成分分析在当前数据的特征空间中寻找一组新的正交基，使得数据的方差最大化。这些新的基向量被称为主成分，每个主成分代表了原始数据中的一种模式。主成分分析在特征提取、噪声滤波和数据可视化等方面发挥着重要作用。主成分分析的主要步骤包括：

(1) 数据预处理：对数据进行中心化处理，使得数据的均值为 0，如公式4-1所

示。

$$x'_{ij} = \frac{x_{ij} - \bar{x}_i}{s_i} \quad (4-1)$$

式中： x'_{ij} 表示标准化后的数据， x_{ij} 表示原始数据， $\bar{x}_i$ 表示第 i 个特征的均值， s_i 表示第 i 个特征的标准差。

(2) 计算协方差矩阵：协方差矩阵反映不同特征之间的相关性，如公式4-2所示。

$$Cov(X) = \frac{1}{n-1}(X - \bar{X})^T(X - \bar{X}) \quad (4-2)$$

式中： n 表示数据集的数量， X 表示标准化后的数据集， $\bar{X}$ 表示每个特征的平均值。

(3) 计算协方差矩阵的特征值和特征向量：通过对协方差矩阵进行特征分解，得到各个主成分的特征值和特征向量，如公式4-3所示。

$$Cov(X)w = \lambda w \quad (4-3)$$

式中： w 是特征向量， λ 是特征值。

(4) 主成分选择：从排序后的特征向量中选取前 k 个作为主成分。

(5) 数据转换：通过将原始数据进行主成分的线性组合映射，得到降维后的数据 Y ，如公式4-4所示。

$$Y = Xw \quad (4-4)$$

图4-1展示了不同主成分数下的方差比例和累计方差贡献率。当主成分数为15时，累计方差贡献率达到0.9998，覆盖了原始光谱中绝大部分的方差信息。因此，本文中采用了15个主成分作为PCA的主成分数。




图 4-1 不同主成分数的方差比例和累计方差贡献率

4.2.2 竞争性自适应重加权采样

竞争性自适应重加权采样法（CARS）算法结合了蒙特卡洛采样和 PLS 模型回归系数，通过自适应加权采样（ARS）选择具有较大回归系数权重的样本点来

建立新的子集，并基于该子集构建 PLS 模型^[65]。CARS 算法通过多次迭代，从具有最小交叉验证均方根误差 (RMSECV) 的子集中选择特征波长。计算步骤如下：

(1) ARS：随机选取原始数据集的 80% 样本建立 PLS 模型，并计算回归系数 c 以获得样本点的权重 w_i ，如公式4-5所示。

$$w_i = \frac{|c_i|}{\sum_{j \in S} |c_j|} \quad (4-5)$$

式中： w_i 表示样本点 i 的权重， c_i 表示样本点 i 的回归系数。

(2) 筛选权重 w_i 波数变量值：根据衰减函数的大小，剔除衰减函数较小的变量值，保留衰减函数较大的变量值。衰减函数的表达式如公式4-6所示。

$$r_i = ae^{-ki} \quad (4-6)$$

式中： $a = \left(\frac{p}{2}\right)^{\frac{1}{N-1}}$ ， $k = \frac{\ln\left(\frac{p}{2}\right)}{N-1}$ ， p 为原始波长点数。

(3) 选择权重较大的 $r_i \times n$ 个波长变量进行 PLS 建模，并计算 RMSECV。

(4) 经过 N 次采样后，ARS 算法得到了 N 组候选的特征波长子集以及对应的 RMSECV 值。根据 RMSECV 最小值所对应的波长变量子集，选择作为最终的特征波长。

本文采用了 5 折交叉验证方法，并进行 50 次蒙特卡洛采样。迭代过程中以 RMSECV 达到最低值时对应的子集为最佳的变量子集。CARS 特征波长提取过程如图4-2-a所示。通过 32 次迭代，得到了最小的 RMSECV 值，并确定了 42 个特征波长变量。这些特征波长变量分别为 932、940、951、975、1019、1036、1070、1077、1093、1096、1109、1127、1145、1165、1188、1191、1202、1207、1215、1268、1271、1284、1294、1299、1310、1312、1315、1379、1391、1437、1450、1461、1498、1501、1513、1522、1525、1550、1592、1636、1640 和 1692 nm，这些特征波长占据了全光谱的 16.41%，它们在平均光谱中的位置如图4-2-b所示。




图 4-2 使用 CARS 提取特征波长过程。(a) CARS 筛选特征波长过程；(b) CARS 特征波长在平均光谱中的位置。

4.2.3 连续投影算法

连续投影算法 (The Successive Projection Algorithm, SPA) 是一种确定性的变量优选方法, 通过投影操作在向量空间中选择线性关系最小的变量组合来解决多元线性回归中的共线性问题。

SPA 的工作原理是采用前向循环选择方法, 从一个起始波长开始, 每次计算中评估未选入波长的投影, 并将具有最大投影向量的波长选入波长组合中。选入的新波长作为新的投影向量, 开始下一轮的投影计算。这个过程不断循环, 直到选出指定数量的波长, 以确保每个新选入的波长与前一个波长之间的线性关系最小, 从而有效地消除冗余信息。SPA 的具体步骤如下:

(1) 初始化: 迭代次数 $n = 1$, 随机选择光谱矩阵中的一列向量作为初始波长 $x_{k(0)}$ 。

(2) 定义余下的波长变量集合 S , 即 $S = j \mid 1 \leq j \leq K, j \notin k(0), \dots, k(n-1)$ 。对 S 中的向量分别计算投影向量 P_x , 如公式 4-7 所示。

$$P_{x_j} = x_j - (x_j^T - x_{k(n-1)}^T) x_{k(n-1)} \left(x_{k(n-1)}^T - x_{k(n-1)}^T \right)^{-1} \quad (4-7)$$

(3) 将具有最大投影的向量作为下一轮的投影向量, 得到 $N \times K$ 个波长组合。对每对 $x_{k(0)}$ 和 N 确定的组合, 建立多元回归模型, 并使用 RMSECV 值评估模型的性能。选择具有最小 RMSECV 的组合, 对应的 $x_{k(0)}$ 和 N 即为最佳的波长组合。

图 4-3-a 为 SPA 特征波长提取过程中 RMSE 的变化情况。当特征波长增加到 33 时, RMSE 达到最低值。特征波长包括 927、932、944、1086、1199、1330、1391、1394、1399、1405、1410、1412、1415、1418、1426、1428、1434、1437、1439、1442、1447、1450、1456、1472、1475、1481、1487、1492、1495、1501、1565、1644、1688 nm, 这些波长占据全光谱的 12.89%, SPA 特征波长在平均光谱中的位置如图 4-3-b 所示。




图 4-3 使用 SPA 提取特征波段. (a) RMSE 随 SPA 特征波长提取变化图; (b) SPA 特征波长在平均光谱的位置.

4.3 建模方法

4.3.1 支持向量回归

支持向量机 (SVM) 是一种基于结构风险最小化原理基础上的一种机器学习方法, 它较好的解决了小样本数据下的高维度、非线性问题^[66]。支持向量回归 (Support Vector Regression, SVR) 是一种基于 SVM 的回归方法。其基本目标是寻找一个超平面, 使得所有数据点到该超平面的距离最小化。这一问题可以用如下公式表示:

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m l_{\epsilon}(f(x_i), y_i) \quad (4-8)$$

式中: C 为损失常数, m 为样本总量, ω 为超平面的法向量 b 表示超平面到远点的截距, x_i 为输入, y_i 为真值, $f(x) = \omega^T \phi(x) + b$ 为回归值, $i = 1, 2, 3, \dots, m$ 。

线性回归方法的目标是拟合一个超平面, 所有不在超平面上的数据点都会对损失函数做出贡献, 因此即使样本数据存在一定程度的噪音, 模型过度优化损失函数时, 就容易出现过拟合的情况。为了解决这个问题, SVR 引入了软间隔 ϵ , 即容忍在超平面上下某个范围内的误差, 这样可以在一定程度上减少过拟合的风险, 从而提高模型的泛化能力。相比于线性回归模型, 训练后的 SVR 模型更能够准确地描述真实的任务, 损失 $l_{\epsilon}(f(x), y)$ 计算如公式4-9所示。

$$l_{\epsilon}(f(x), y) = \begin{cases} |f(x) - y| - \epsilon & , |f(x) - y| - \epsilon > 0 \\ 0 & , \text{其它} \end{cases} \quad (4-9)$$

引入松弛变量 ϵ_i 和 $\hat{\epsilon}_i$, 可以将公式4-8化简为公式4-10。

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m (\epsilon_i + \hat{\epsilon}_i) \quad s.t. \begin{cases} f(x) - y \geq \epsilon + \hat{\epsilon} & , \hat{\epsilon} \geq 0 \\ y - f(x) \leq \epsilon + \epsilon_i & , \epsilon_i \geq 0 \end{cases} \quad (4-10)$$

对于上述优化问题, 引入 α , $\hat{\alpha}$, 由拉格朗日乘子法对式4-10求解其对偶问题, 如公式4-11所示。

$$\begin{aligned} \max_{\alpha, \hat{\alpha}} & -\epsilon(\hat{\alpha}_i + \alpha_i) + \sum_{i=1}^m y_i(\hat{\alpha}_i - \alpha_i) - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\hat{\alpha}_i - \alpha_i)(\hat{\alpha}_j - \alpha_j) \varphi(x_i)^T \varphi(x_j) \\ s.t. & \begin{cases} \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) = 0 \\ 0 \leq \hat{\alpha}_i, \alpha_i \leq C \end{cases} \end{aligned} \quad (4-11)$$

式中: $\alpha, \hat{\alpha}$ 是拉格朗日算子。

引入核函数 $\Phi(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$, 将低维的样本空间映射为高维的特征空间来解决非线性问题, 回归函数的解 $f(x)$ 如公式4-12所示。

$$f(x) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \Phi(x_i, x_j) + b \quad (4-12)$$

SVR 模型的性能受到所选核函数的影响。在表4-1中,列出了 SVR 常用的核函数,包括线性核函数、多项式核函数和径向基核函数。线性核函数适用于数据线性可分的情况,其对应的 SVR 模型可以看作是对输入空间的线性划分。多项式核函数可以将原本线性不可分的数据映射到更高维的空间中,从而使得数据在该空间中线性可分。但是,需要注意的是,过高的多项式次数可能会导致模型过拟合。径向基核函数(RBF)则能够将输入数据映射到一个无穷维的特征空间,从而使得数据在该空间中线性可分。它的稳定性较强,收敛速度较快,在近红外光谱领域应用广泛^[67]。由于本文基于近红外光谱对绿茶加工中的含水率进行检测,考虑到近红外光谱具有非线性特点,因此采用 RBF 作为核函数,以达到最佳的模型性能。

表 4-1 SVR 常用的三种核函数

核函数名称	核函数表达式	核函数参数
径向基核函数	$K(x_i, x_j) = \exp(\gamma \ x_i - x_j\)$	γ 为决策边界的曲率
多项式核函数	$K(x_i, x_j) = (x_i^T x_j + 1)^d$	d 为多项式次数
线性核函数	$K(x_i, x_j) = x_i^T x_j$	无

4.3.2 BP 神经网络

BP 神经网络 (Backpropagation Neural Network, BPNN) 是一种基于反向传播算法的多层前馈神经网络,用于模式识别、分类和回归等任务^[68]。其起源可追溯到上世纪 80 年代,由于具备强大的学习能力和灵活性,已成为神经网络领域的经典模型之一^[69]。BPNN 通常由三层构成,分别是输入层、隐藏层和输出层(如图4-4所示)。该网络通过多层神经元之间的连接和权重调整,将输入数据映射到输出空间。神经元是 BPNN 的基本组成部分,每个神经元接收来自前一层神经元的输入,经过加权和非线性变换得到输出,并将输出传递给后一层神经元。通过反向传播算法优化神经元之间的连接和权重,使得神经网络具备学习和适应新数据的能力。确定 BPNN 的网络结构后,其基本步骤包括:

(1) 权重和阈值初始化:权重和阈值初始化在 BPNN 中起着重要作用,对网络性能产生显著影响。一般情况下,可以通过随机初始化或经验设定的方式来确定初始值。

(2) 前向传播:指神经网络从输入层到输出层的计算过程。在该过程中,神经元接收上一层神经元的输出,并计算本层神经元的输出值,以实现从输入向量 x 到输出向量 y 的传递。假设网络包含 L 个层,第 l 层有 n_l 个神经元,则第 l 层




图 4-4 BPNN 示例图

的输出向量 $a^{(l)}$ 计算如公式4-13所示。

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)}) \quad (4-13)$$

式中: $W^{(l)}$ 是一个 $n_l \times n_{l-1}$ 的权重矩阵, $b^{(l)}$ 是一个维度为 n_l 的偏置向量, f 表示激活函数。

(3) 计算误差: 包括计算输出层误差和计算隐藏层误差。

输出层误差 $\delta^{(L)}$ 计算如公式4-14所示。

$$\delta^{(L)} = \nabla_a L \odot f'(z^{(L)}) \quad (4-14)$$

式中: $\odot$ 表示元素对应乘积, $\nabla_a L$ 是损失函数对输出层输出向量 y 的梯度, $f'(z^{(L)})$ 是输出层激活函数的导数。

隐藏层误差 $\delta^{(l)}$ 计算如公式4-15所示。

$$\delta^{(l)} = \left((W^{(l+1)})^T \delta^{(l+1)} \right) \odot f'(z^{(l)}) \quad (4-15)$$

式中: $(W^{(l+1)})^T$ 是第 $l+1$ 层到第 l 层的权重矩阵的转置。

(4) 反向传播: 通过计算输出误差和误差在网络中的传播, 来更新网络中的权重和阈值。权重和阈值的更新可以通过梯度下降法实现。

权重的更新 Δw_{ij} 如公式4-16所示。

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}} \quad (4-16)$$

阈值的更新 Δb_j 如公式4-17所示。

$$\Delta b_j = -\eta \frac{\partial E}{\partial b_j} \quad (4-17)$$

式中： η 表示学习率， $\frac{\partial E}{\partial w_{ij}}$ 和 $\frac{\partial E}{\partial b_j}$ 分别表示损失函数对权重和阈值的偏导数。

更新后的权重 $w_{ij}(t+1)$ 和阈值 $b_j(t+1)$ 如公式4-18和4-19所示。

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij} \quad (4-18)$$

$$b_j(t+1) = b_j(t) + \Delta b_j \quad (4-19)$$

(5) 迭代训练：通过多次迭代训练，反复进行前向传播、误差计算、反向传播和参数更新，直到达到预设的停止条件。常见的停止条件包括达到最大迭代次数、误差达到阈值等。

4.4 特征波长建模结果对比

采用 SG 光谱方法对光谱进行预处理，分别采用 PCA、CARS 和 SPA 提取光谱的特征波长，建立 PLSR、SVR 和 BPNN 三种模型进行建立绿茶含水率检测模型，来筛选出预测效果最佳的模型。

4.4.1 特征波长建模结果

表 4-2 展示了三种特征波长提取方法在 PLSR 模型中的结果。从表 4-2 可知，在校正集中，PLSR 模型的拟合效果相对较稳定。在预测集中，采用 PCA 方法的预测性能最优，其 R_{CV}^2 、RMSECV、 R_p^2 、RMSEP 和 RPD 分别为 0.9701、2.17%、0.9651、2.34% 和 5.3544。图 4-5 显示了 PLSR 模型的预测结果。虽然该模型是三个模型中表现最好的一个，但在绿茶的全部含水率区间内仍不能实现较为准确的预测效果，只有极少数叶片含水率的预测值与真实值误差较小。因此，该模型的预测效果一般。

表 4-2 三种特征波长提取方法的 PLSR 模型结果

方法	R_{CV}^2	RMSECV (%)	R_p^2	RMSEP (%)	RPD
PCA	0.9701	2.17	0.9651	2.34	5.3544
CARS	0.9708	2.14	0.9597	2.51	4.9823
SPA	0.9648	2.36	0.9609	2.48	5.0603

在 SVR 模型中，采用径向基函数（Radial Basis Function, RBF）作为核函数，超参数 C 值为 10， γ 值为 1， ϵ 值为 0.1。表4-3展示了使用三种特征波长提取方法




图 4-5 PCA+PLSR 模型结果

建立的 SVR 模型结果。从表4-3可以看出，三种方法的 SVR 模型均取得了较好的预测效果，其 R_P^2 值均大于 0.9650。经过比较，发现基于主成分分析提取的特征波长所建立的 SVR 模型具有最佳的预测效果，其 R_{CV}^2 、RMSECV、 R_P^2 、RMSEP 和 RPD 分别为 0.9721、2.10%、0.9760、1.94% 和 6.4587。SVR 模型在预测集的预测结果如图4-6所示，从图中可以直观地观察到，在叶片的全部含水率区间内，SVR 预测模型的预测准确性优于 PLSR 模型，展现出了优秀的预测准确性。

表 4-3 三种特征波长提取方法的 SVR 模型结果

方法	R_{CV}^2	RMSECV (%)	R_P^2	RMSEP (%)	RPD
PCA	0.9721	2.10	0.9760	1.94	6.4587
CARS	0.9627	2.45	0.9664	2.29	5.4581
SPA	0.9643	2.38	0.9694	2.19	5.7126

在 BPNN 模型中，隐含层神经元的个数设置为 30 个，网络参数设置包括训练次数为 1000 次和学习速率为 0.01。表4-4展示了使用三种特征波长提取方法建立的 BPNN 模型结果。从表4-4中可以得出，三种特征波长提取方法在 BPNN 模型中都表现出良好的预测效果。其中基于 CARS 的 BPNN 模型在预测效果上最优，其 R_{CV}^2 、RMSECV、 R_P^2 、RMSEP 和 RPD 分别为 0.9625、2.63%、0.9678、2.25% 和 5.5746。图4-7展示了 BPNN 在预测集中的预测结果。从图中可以直观地观察到，BPNN 预测模型预测效果在 PLSR 模型和 SVR 模型之间，在预测准确度上表现出不错的结果。




图 4-6 PCA+SVR 模型结果

表 4-4 三种特征波长提取方法的 BPNN 模型结果

方法	R_{CV}^2	RMSECV (%)	R_P^2	RMSEP (%)	RPD
PCA	0.9888	1.32	0.9621	2.44	5.1355
CARS	0.9625	2.63	0.9678	2.25	5.5746
SPA	0.9535	2.66	0.9614	2.46	5.0906




图 4-7 CARS+BPNN 模型结果

4.4.2 三种特征波长提取方法对比

各模型的最优特征波长提取方法预测结果整理如下：建立于 PCA 提取的特征波长的 PLSR 预测模型的预测效果最佳，相关指标包括 R_{CV}^2 、RMSECV、 R_P^2 、

RMSEP 和 RPD, 分别为 0.9701、2.17%、0.9651、2.34% 和 5.3544。建立于 PCA 提取的特征波长的 SVR 预测模型的预测效果最佳, 相关指标为 R_{CV}^2 、RMSECV、 R_P^2 、RMSEP 和 RPD, 分别为 0.9721、2.10%、0.9760、1.94% 和 6.4587。: 建立于 CARS 提取的特征波长的 BPNN 预测模型的预测效果最佳, 相关指标为 R_{CV}^2 、RMSECV、 R_P^2 、RMSEP 和 RPD, 分别为 0.9721、2.10%、0.9760、1.94% 和 6.4587。

综上所述, 在特征波长提取方法中, PCA 提取特征波长的效果最优。在回归模型中, SVR 模型预测结果更加准确。使用 PCA 提取特征波长并建立 SVR 预测模型时, 取得最佳的预测结果, 能够实现对绿茶加工过程中含水率的快速检测。

4.5 本章小结

本章将详细介绍论文中采用的三种特征波长提取方法的原理和实现过程。随后, 将这些方法与三种预测模型相结合, 对预测结果进行详细分析, 并使用模型评价标准进行比较。经过比较分析, 本研究发现, 采用 PCA 提取的特征波长建立的 SVR 模型表现最佳。相关指标包括 R_{CV}^2 、RMSECV、 R_P^2 、RMSEP 和 RPD, 分别为 0.9721、2.10%、0.9760、1.94% 和 6.4587。最后, 结合第三章的研究内容, 得出以下结论: 在预处理、特征波长提取和建立预测模型的过程中, 最佳的组合方式是采用 SG 平滑作为预处理方法, PCA 作为特征波长提取方法, 并以 SVR 模型进行建模。该组合方式能够快速检测绿茶加工过程中的含水率。本章的研究为绿茶含水率预测提供了有效的方法和理论支持。

第 5 章 基于改进 Stacking 预测模型的建立

5.1 引言

第四章结合特征波长提取和回归模型验证了方法的有效性。然而，特征波长方法的泛化能力可能受限，因其设计依赖于特定的数据集和任务。同时，由于光谱数据的高维性、数据质量的不确定性和样本复杂性等问题，单一回归模型在某些情况下可能随机性较高，导致预测准确性和稳定性下降^[70]。为了提升模型预测性能，模型融合是一种有效方法。其中，Stacking 是一种基于元学习的模型融合技术，在定量预测领域得到广泛应用。目前将 Stacking 集成学习应用于含水率检测还少有研究，本章引入并改进了 Stacking 集成学习，旨在研究 Stacking 集成学习在绿茶含水率预测中的可行性和有效性。为了提升 Stacking 集成学习的性能，本章将对基学习器的性能进行改进，并优化了它们之间的组合方式。

超参数的选取是决定基学习器性能的关键因素。目前有多种超参数寻优方法，如网格搜索、随机搜索、贝叶斯优化^[71]。这些方法在低维线性寻优问题中效果显著。但在高维非线性寻优问题中，这些方法需要大量计算资源。启发式算法是一类基于经验和启发式策略的搜索和优化算法。其目标是在合理的时间内找到尽可能好的解决方案，具有强大的全局搜索能力。倪鸿飞等人^[72]通过波段筛选和遗传算法优化极限学习机，快速测定了银参通络胶囊工艺中洗脱液中成分含量。耿莹蕊等人^[73]则采用灰狼算法和粒子群算法优化 SVM 参数，实现了对烟叶产地的快速准确鉴别。可以发现，启发式算法在近红外光谱领域的模型参数优化具有巨大潜力。遗传算法是其中的典型代表，本文提出了一种自适应策略遗传算法，可用于优化多个模型的超参数。该算法通过根据个体适应度排名和种群适应度的离散程度调整交叉和变异概率，有效避免早熟现象和局部最优解，并快速找到全局最优解，提高模型的性能。

对于基学习器组合的相关性，一般选取原理不同的模型相关性较低，然而基学习器组合众多，选取基学习器没有定量的方法进行判断。本文引入 Kendall 相关性分析来判断基学习器的相关性，其原理是根据模型的预测结果进行相关性计算，其绝对值越接近 0，相关性越低，该方法可有效提升基学习器组合筛选的效率，并能提高 Stacking 集成学习的预测性能^[74]。

本章建立改进 Stacking 含水率预测模型，探讨了 Kendall 相关性分析在绿茶含水率检测中的有效性以及改进 Stacking 集成学习在该领域的适用性、预测性能和泛化能力，为近红外光谱的含水率检测提供一种新的技术实现。

5.2 集成学习理论概述

集成学习是一种机器学习方法,通过组合多个基学习器的预测结果来获得更准确、鲁棒性更强的预测模型。其基于两个假设:基学习器的性能存在差异,即某些学习器更适合某些数据集或某些特征;基学习器的错误是相互独立的,即不同的学习器在不同的样本和特征上可能会出现不同的错误。集成学习通过投票、平均等方式对多个基学习器的结果进行结合,可以减少模型的方差并提高模型的泛化能力。

集成学习通常分为三类: Bagging、Boosting 和 Stacking, Bagging 集成学习算法通过 bootstrap 自助采样的方式从原始数据集中生成多个不同的数据集,并针对每个数据集训练一个基模型。Boosting 集成学习算法是一种能够将许多弱模型组合成一个强模型的技术,从而提高模型的预测性能。Stacking 集成学习算法通过结合多种基础模型的预测结果,训练一个元模型来提高预测精度。表5-1为三类集成学习方法的对比,这些方法已在其他领域取得了良好的效果。例如, Choi 等^[75] 使用 Bagging 集成策略来预测太阳能输出,并分别使用 RF、XGBoost 和 LightGBM 模型作为基学习器进行 Bagging 集成。Ni 等人^[76] 将 XGBoost 方法与高斯混合方法相结合,用于月度水流预测,并得出了这种先进树形模型优于 SVM 的结论。实验结果表明,所有模型在 Bagging 集成后都能有效地提高预测准确度。Li 等^[77] 提出了一种基于卷积神经网络 (CNN) 和 Stacking 集成模型的贷款风险预测模型,利用 CNN 提取 Stacking 算法结果中隐藏的局部空间特征,提高模型的泛化能力,充分发挥 Stacking 算法的泛化能力和 CNN 算法的特征提取能力,结果表明, Stacking+CNN 的预测模型在预测准确率和召回率方面优于单一模型和其他集成模型。

5.2.1 随机森林

随机森林(Random Forest, RF)是一种基于 Bagging 的集成学习方法。Bagging 是一种基于样本随机有放回抽样的方法,通过对多个基分类器的结果进行投票或平均来提高模型的泛化能力和稳定性^[78]。在 RF 中,每个基回归器都是一个决策树,通过随机选择特征和样本来构建不同的决策树。最终,通过平均的方式将多个决策树的结果集成,得到 RF 的最终结果,其训练过程如图5-1所示。相对于单棵决策树, RF 可以降低过拟合风险,同时提高预测精度和泛化能力。

具体来说,假设有 N 个样本, M 个特征, T 棵决策树,每个决策树使用 n_{tree} 个样本和 m_{tree} 个特征进行训练,对于一个新样本 x , 它的预测结果 $\hat{y}(x)$ 如公

表 5-1 三种集成学习方法的对比

方法	核心思想	基学习器类型	训练效率	结构	代表模型
Bagging	基于自助采样法, 通过并行地训练多个同质的基学习器, 最终将它们的结果进行平均或投票来得到最终结果。	同质	高	并行	RF
Boosting	通过加权训练不同的基学习器, 使得预测偏差较大的样本得到更多的关注, 不断迭代地训练出一系列基学习器, 最终将它们组合成一个强学习器。	同质	低	串行	AdaBoost
Stacking	通过将多个不同的基学习器的预测结果作为新的训练数据, 训练一个元学习器来进一步提高模型的性能。	异质	低	串行	元学习

式5-1所示。

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T y_{\text{tree},t}(x) \quad (5-1)$$

式中: $y_{\text{tree},t}(x)$ 表示第 t 棵决策树对样本 x 的预测结果。




图 5-1 Bagging 训练流程

5.2.2 自适应提升算法

自适应提升算法 (Adaptive Boosting, AdaBoost) 是一种基于 Boosting 集成学习的机器学习算法。AdaBoost 算法的思想是加权的方式来集成多个弱学习器, 算法会根据上一轮的结果来调整每个样本的权重, 使得上一轮被预测偏差大的样本的权重变大, 而被预测偏差小的样本的权重变小^[79]。算法会利用更新后的样本权重来训练一个新的弱学习器, 该学习器的输出结果会被用于更新全局模

型，同时本轮训练的弱学习器的权重也会被计算出来。这个过程会一直持续达到预设的最大迭代次数或者误差足够小为止，其训练过程如图5-2所示。其核心是将加权误差最小化，AdaBoost 的预测值 $F(x)$ 如公式5-2所示。

$$F(x) = \sum_{m=1}^M \alpha_m h_m(x) \quad (5-2)$$

式中： $h_m(x)$ 表示第 m 个弱学习器的预测值， α_m 表示该弱学习器的权重。在每轮迭代中，新的弱学习器的权重 α_m 会被计算出来，使得之前所有弱学习器的加权误差最小化。最终，所有弱学习器的权重将被用于计算最终的预测结果。




图 5-2 boosting 训练流程

5.2.3 Stacking 集成学习

Stacking 是一种基于元学习的集成学习策略，通过将多个不同的基学习器的预测结果作为新的训练数据，训练一个元学习器来进一步提高模型的性能^[80]。Stacking 训练过程主要包括两个阶段：第一个阶段是使用多个基础模型对数据进行预测得到一系列预测结果，第二个阶段是使用这些预测结果作为新的特征，训练一个元模型，其训练过程如图5-3所示。在 Stacking 测试过程中，将测试数据输入到训练好的基学习器中进行预测，并将多个基学习器的预测结果输入到元学习器中进行集成，从而得到最终的预测结果。相较于 Bagging 和 Boosting，Stacking 采用了异质基学习器，这使得它在处理复杂数据集和不同类型的数据时具有优势。异质基学习器可以更广泛地捕捉数据中的特征和规律，从而更好地适应不同的数据类型和任务需求，具有更高的泛化能力。Stacking 通过训练元学习




图 5-3 Stacking 训练和预测流程图

器来结合多个基学习器的预测结果，进一步提高了模型的性能，并具有一定的可解释性，能够帮助人们更好地理解模型的工作原理。在选择基学习器时，需要避免选择性能较差或组合不当的基学习器，以避免模型出现过拟合或欠拟合问题。选择不同的基学习器并减少它们之间的相关性，可以保持它们的独立性并避免冗余。综上所述，Stacking 具有更高的泛化能力、更好的关联关系捕捉能力、更好的过拟合控制能力、更高的可解释性等优势。

5.3 改进 Stacking 集成学习算法

在 Stacking 集成学习中，选择合适的基学习器和元学习器是模型性能的关键点。基学习器的选取应该考虑到性能和多样性，选择性能较好的基学习器，尽量减少它们之间的相关性，保持它们的独立性，避免冗余，以此使得模型之间信息互补。同时，选择能够处理非线性关系的元学习器将提高对多个基学习器的预测结果的关联性捕捉的能力。

本文旨在提高绿茶含水率检测模型的性能和泛化能力。本文选用了 PLSR、SVR、BPNN、RF 和 AdaBoost 共五种回归模型作为基学习器的候选集。使用交叉验证技术在训练过程中充分利用训练集，提高模型的泛化能力。在基学习器的选择方面，选取训练集中 5 折交叉验证的 RMSECV 最低的基学习器作为基准学习器，将基准学习器与其他四种回归模型的预测结果进行 Kendall 相关性分析，选出与基准学习器相关性值最低的两个回归模型作为基学习器组。

Kendall 相关性分析是一种用于衡量两个变量之间相关性的方法。它可以评估两个变量的等级相似性。该方法基于一个假设：两个变量的值之间存在单调关系，即当一个变量的值增加时，另一个变量的值也会相应地增加或减少。如果两个变量之间存在这种单调关系，则它们的 Kendall 相关系数为正；如果它们的值没有任何单调关系，则相关系数为零；如果它们的值之间存在反向的单调关系，则相关系数为负。Kendall 相关系数的计算方法是通过比较两个变量之间的

等级顺序,从而得出它们的相关系数。具体地,给定两个长度为 n 的样本 x 和 y , Kendall 相关系数 τ 的计算如公式5-3所示。

$$\tau = \frac{2}{n(n-1)} \sum_{i < j} \text{sgn}(x_i - x_j) \text{sgn}(y_i - y_j) \quad (5-3)$$

式中: $\sum_{i < j}$ 表示对所有 $i < j$ 的组合进行求和,符号函数 $\text{sgn}(x_i - x_j)$ 和 $\text{sgn}(y_i - y_j)$ 分别表示 $x_i - x_j$ 和 $y_i - y_j$ 的正负号,即 x_i 和 x_j , y_i 和 y_j 之间的大小关系。如果 x_i 比 x_j 大,则 $\text{sgn}(x_i - x_j) = 1$, 否则 $\text{sgn}(x_i - x_j) = -1$ 。类似地,如果 y_i 比 y_j 大,则 $\text{sgn}(y_i - y_j) = 1$, 否则 $\text{sgn}(y_i - y_j) = -1$ 。 τ 的取值范围为 $[-1, 1]$, 其中 $\tau = -1$ 表示两个基学习器完全负相关, $\tau = 1$ 表示完全正相关, $\tau = 0$ 表示无相关性。当基学习器之间的 τ 绝对值越接近 0 时,它们之间的独立性就越强,因此越适合作为 Stacking 的基学习器,从而提高 Stacking 集成学习的泛化能力。

为了提高 Stacking 集成学习的预测精度,本文引入自适应参数遗传算法对基学习器的超参数进行优化,改进 Stacking 集成算法的训练框架如图5-4所示,具体步骤如下:

(1) 使用 Kennard-Stone 算法按 4:1 的比例划分训练集和预测集,本文采用第三章数据集划分和奇异样本剔除后的数据,并对光谱进行预处理。

(2) 使用 PLSR、SVR、BPNN、RF 和 AdaBoost 进行训练,并使用 5 折交叉验证和自适应遗传算法进行超参数优化。

(3) 对优选超参数后的基学习器在预测集上预测,对基学习器预测结果两两进行 Kendall 相关分析,选择与基准学习器 Kendall 相关系数最低的两个模型作为改进 Stacking 集成学习的基学习器组。

(4) 将 (3) 中的基学习器组的预测结果作为新的特征集,使用元学习器进行拟合,得到改进 Stacking 集成学习模型,以此实现绿茶含水率检测模型。

5.4 基学习器改进

5.4.1 自适应概率遗传算法

遗传算法 (Genetic Algorithm, GA) 是一种基于进化和自然选择原理的优化算法。它模拟了进化过程中的“选择、交叉、变异”等基本生物行为,以求解复杂问题的最优解^[81]。该算法将每个可能的解视为一个个体,并通过模拟自然界中的“适者生存”和“优胜劣汰”选择机制进行不断的进化。每一代的个体都在环境中逐步适应,以逼近最优解。这种方法能够使得算法逐步趋近最优解,并在优化问题中发挥出色的效果。

在绿茶含水率检测当中,模型的超参数的选择对结果具有关键影响。图5-5为遗传算法参数优化模型超参数的流程图,其基本步骤如下:




图 5-4 改进 Stacking 集成学习模型训练框架

(1) 编码超参数集和适应度函数的确定。将超参数集编码为实数或二进制数，本文使用整数表示离散值，使用实数表示连续值；适应度函数是遗传算法中的关键部分，本文的适应度函数为训练集 5 折交叉验证的均方根误差 (RMSE)。

(2) 初始化种群：随机生成初始种群。

(3) 评估适应度：将适应度函数应用于种群中的每个个体，以评估它们的适应度。

(4) 选择、交叉和变异操作。选择一些适应度较高的个体，保留它们并排除适应度较低的个体；对保留的个体进行交叉和变异操作，产生新的个体。

(5) 重复 (3) 和 (4)，直到达到结束条件。




图 5-5 遗传算法参数优化流程图

传统遗传算法具有较强的全局搜索能力，但在搜索空间较大、维度较高、需要同时优化多个参数的情况下，其局部搜索能力相对较弱，容易陷入局部最优解，从而降低参数优化效率^[82]。为此，本文采用自适应遗传算法（AGA）来提高搜索效率和优化结果质量。该算法可以根据个体适应度自适应地调整遗传算法中的参数，具有更好的全局和局部搜索能力，从而加快算法的收敛速度。与传统遗传算法相比，改进的遗传算法会根据个体适应度排名和种群适应度离散程度自适应调整个体的交叉和变异概率。个体的交叉 P_c 和变异概率 P_m 的计算如公式5-7和5-8所示。

$$EX = f_{avg} = \frac{f_1 + f_2 + \cdots + f_M}{M} \quad (5-4)$$

$$DX = \frac{f_1^2 + f_2^2 + \cdots + f_M^2}{M} - f_{avg}^2 \quad (5-5)$$

$$\partial = \frac{\sqrt{DX}}{EX}, EX > 0 \quad (5-6)$$

$$P_c = \begin{cases} k_1 & , f \geq f_{avg} \\ k_1 - (k_1 - k_2) \cdot \frac{1 - e^{-k_3 \cdot \partial}}{1 + e^{-k_3 \cdot \partial}} \cdot \frac{f_{avg} - f}{f_{max} - f_{avg}} & , f < f_{avg} \end{cases} \quad (5-7)$$

$$P_m = \begin{cases} k_4 - (k_4 - k_5) \cdot \frac{2 \cdot e^{-k_6 \cdot \partial}}{1 + e^{-k_6 \cdot \partial}} \cdot \frac{f - f_{avg}}{f_{max} - f_{avg}} & , f \geq f_{avg} \\ k_4 & , f < f_{avg} \end{cases} \quad (5-8)$$

式中： M 是种群中的个体数量， P_C 是个体交叉概率， P_M 是个体变异方差概率， EX 和 f_{avg} 是当前种群适应度的均值， DX 是适应度的方差， ∂ 是种群变异系数，用于评估种群的分散程度， f 是一个个体的适应性， f_{max} 是当前种群适应性的最大值， k_1 、 k_2 、 k_3 、 k_4 、 k_5 和 k_6 是预先确定的常数。

本文提出的 P_c 和 P_m 值不仅取决于适应度排名，还与种群适应度离散系数 ∂ 相关。具体而言，在 P_c 中，当个体适应度大于种群平均适应度时，一个固定较大的概率被设置以增加优良基因交叉的机会，同时保留种群的优良机会；当个体适应度小于种群平均值时，个体适应度排名越低， P_c 随之减小。在 P_m 中，当个体适应度小于种群平均适应度时，一个固定较大的变异概率被设置，以增加个体突变的机会；当个体适应度大于种群平均值时，适应度排名越高， P_m 越小，减少优良基因被破坏的可能。当种群适应度分布越分散时，离散系数 ∂ 值越大，交叉概率 P_c 就越小，变异概率 P_m 就越大，以维持种群的多样性，避免过早陷入局部最优解。相反，当种群适应度分布越集中时，离散系数 ∂ 值越小，交叉概率 P_c 就越大，变异概率 P_m 就越小，以加速算法的收敛速度。 P_c 和 P_m 与变异系数 ∂ 关系如图 5-6 所示。从图中可以看出， P_c 和 P_m 的变化幅度可以通过改变 k 值进行调整， k 值的设定需要根据实际问题进行调整。因此，采用上述策略可以动态调整交叉率和变异率，从而有效地避免早熟现象和局部最优解，并快速找到全局最优解，该方法可用于优化模型超参数，从而提高模型性能和预测精度。




图 5-6 P_c 和 P_m 与变异系数 ∂ 关系. (a) P_c ; (b) P_m .

5.4.2 基学习器超参数寻优

超参数在机器学习模型的训练中发挥着关键作用。本文对 PLSR、SVR、BPNN、RF 和 AdaBoost 的超参数进行优化，各个模型需要被优化的超参数详情如表 5-2 所示。在 AGA 算法中，使用 5 折交叉验证的 RMSECV 作为适应度函数，对于连续值采用实数编码，对于离散值转化为整数。AGA 的为进化次数为 100，种群个数

为 20, k_1 、 k_2 、 k_3 、 k_4 、 k_5 和 k_6 分别设置为 0.8、0.3、2、0.2、0.01、2。

表 5-2 需要被优化的超参数详情

模型	超参数	含义	作用	默认值
PLSR	n_components	特征数	压缩数据	2
SVR	C	惩罚系数	确定错误容忍度	1.0
	gamma	核函数宽度	控制样本点影响范围	auto
	epsilon	残差容忍度	控制样本点的支持向量	0.1
BPNN	learning_rate	学习率	控制权重的更新速度	0.001
	hidden_size	隐层节点数	控制模型复杂度	100
	activation	激活函数	控制神经元激活状态	relu
RF	n_estimators	决策树数	提高模型稳定性	100
	max_depth	决策树深度	控制模型复杂度	None
	max_features	最大特征数	控制每棵决策树的属性随机性	auto
Adaboost	base_estimator	基模型	提高模型学习能力	决策树
	learning_rate	学习率	控制基学习器的重要性	1.0




图 5-7 AGA 优化不同模型超参数的迭代过程. (a) PLSR; (b) SVR; (c) BPNN; (d) RF; (e) AdaBoost.

图5-7为使用 AGA 分别优化五种模型超参数的寻优过程, 图中, x 轴为 AGA 的进化次数, y 轴为 5 折交叉验证的 RMSECV, 图中的虚线代表 RMSECV 最低点的迭代次数, 实线为每个进化次数中当前种群最优个体的 RMSECV 值。从图5-7可知, PLSR、BPNN、SVR、RF、AdaBoost 分别在迭代第 17、84、73、76 和 58 次达到了最佳的预测结果。此可说明, 超参数的范围与模型寻优速率有关。

当待优化超参数的范围较小时, 寻优速率更快。例如, 在 PLSR 和 AdaBoost 方法中, 寻优范围较小, 在前 60 次就找到了最优解。BPNN、SVR 和 RF 都有两个或以上的超参数需要优化, 参数寻优范围较广, 因此需要进行更多的迭代寻优, 但最佳的参数组合都能够在 100 次迭代过程中找到, 这体现了 AGA 在参数寻优时的效率。表5-3展示了五种回归模型在 AGA 优化过程中的模型参数范围和最优参数。根据超参数寻优结果, 五种机器学习的最优超参数集与默认值不同, 因此有必要使用 AGA 方法对模型超参数进行寻优。

表 5-3 AGA 优化模型参数范围和最优参数集

模型	超参数	含义	寻优范围	最优值
PLSR	n_components	特征数	[2,100]	23
SVR	C	惩罚系数	[1e-6,1000]	973.66
	gamma	核函数宽度	[1e-6,100]	3.72
	epsilon	残差容忍度	[1e-6,1.0]	0.002
BPNN	learning_rate	学习率	[1e-3,0.2]	0.05
	hidden_size	隐层节点数	[20,150]	67
	activation	激活函数	relu, sigmoid, tanh	relu
RF	n_estimators	决策树数	[20,200]	53
	max_depth	决策树深度	[2,15]	9
	max_features	最大特征数	[20,100]	48
Adaboost	base_estimator	基模型	决策树, RF	RF
	learning_rate	学习率	[0.01,1.0]	0.13

5.4.3 Kendall 相关性分析

对经过 AGA 优化超参数的 PLSR、SVR、BPNN、RF 和 AdaBoost 模型进行预测, 预测结果如图5-8所示。图中 x 轴表示绿茶含水率的测量值, y 轴表示绿茶含水率的预测值。红色直线表示拟合 x 和 y 之间的一元线性回归直线。直线越接近 $y = x$, R_{CV}^2 和 R_P^2 越接近 1, RMSECV 和 RMSEP 越小, RPD 值越大, 说明模型的预测效果越好。可以发现, AdaBoost 的预测效果最佳, 因此选择了 AdaBoost 作为基准基学习器。并计算五种模型在预测集上的预测结果的相关系数, 结果如图5-9所示。

根据图5-9, PLSR、SVR、BPNN、RF 和 AdaBoost 在预测集中的预测结果的 Kendall 相关系数分别为 0.86、0.91、0.80 和 0.93。在本文中, AdaBoost 所采用的基模型为 RF, 因此二者在预测结果上具有高度相似性, 进而导致相关系数较大。SVR 和 AdaBoost 的相关系数也较高, 这可能归因于这两种算法对于非线性、小样本和噪声等数据问题具有相对较强的鲁棒性和适应性, 从而预测结果通常较




图 5-8 AGA 优化不同模型的预测结果. (a) PLSR; (b) SVR; (c) BPNN; (d) RF; (e) AdaBoost.




图 5-9 五种回归模型的 Kendall 相关性分析结果

为可靠, 进而使得 Kendall 相关系数较高。相比之下, PLSR 和 BPNN 的相关系数较低, 原因在于 PLSR 是线性回归模型, 而 BPNN 易受噪声或异常值的影响, 导致预测精度较低, 从而相关系数相应下降。

在选择基学习器时, 需考虑性能、多样性和差异性, 以全面捕捉数据集特征。基学习器间应低相关, 以降低方差、提高预测性能。因此, 本研究选择了预测精度最高的 AdaBoost, 以及与之相关性最低的 PLSR 和 BPNN 作为基学习器。元学习器需异质且具备泛化能力、鲁棒性和可扩展性。鉴于 SVR 对超参数敏感, 本文采用 RF 作为改进 Stacking 的元学习器。

5.5 模型建立与验证

5.5.1 验证 Kendall 相关性分析在基学习器选择的有效性

为了验证本文所提出的 Kendall 相关性分析在基学习器选择中的有效性, 本研究采用 RF 作为元学习器, 并比较了三种、四种和五种基学习器进行组合的 Stacking 模型的预测效果。相应的结果见表5-4。值得注意的是, 前十个模型是采用三种基学习器组合方式, 第 11 至 15 个模型是使用四种基学习器组合方式, 而最后一个模型则采用了五种基学习器的组合方式。

表 5-4 不同模型集成的 Stacking 模型表现比较

模型	R_{CV}^2	RMSECV	R_P^2	RMSEP	RPD	排名
PLSR_SVR_BPNN	0.9890	1.35	0.9803	1.76	7.1270	14
PLSR_SVR_RF	0.9891	1.24	0.9856	1.50	8.3367	11
PLSR_SVR_AdaBoost	0.9933	0.95	0.9919	1.13	11.1745	2
PLSR_BPNN_RF	0.9881	1.46	0.9750	1.98	6.3190	16
PLSR_BPNN_AdaBoost	0.9959	0.73	0.9953	0.86	14.5527	1
PLSR_RF_AdaBoost	0.9905	1.05	0.9818	1.69	7.4125	13
SVR_BPNN_RF	0.9908	1.18	0.9866	1.45	8.6314	8
SVR_BPNN_AdaBoost	0.9923	1.10	0.9890	1.31	9.5532	5
SVR_RF_AdaBoost	0.9931	1.17	0.9861	1.48	8.4840	10
BPNN_RF_AdaBoost	0.9922	1.01	0.9887	1.33	9.4033	6
PLSR_SVR_BPNN_RF	0.9899	1.21	0.9883	1.35	9.2455	7
PLSR_SVR_BPNN_AdaBoost	0.9948	0.96	0.9903	1.24	10.1378	3
PLSR_SVR_RF_AdaBoost	0.9918	1.17	0.9891	1.31	9.5910	4
PLSR_BPNN_RF_AdaBoost	0.9916	1.11	0.9782	1.85	6.7768	15
SVR_BPNN_RF_AdaBoost	0.9899	1.25	0.9877	1.39	9.0316	8
PLSR_SVR_BPNN_RF_AdaBoost	0.9901	1.20	0.9844	1.57	7.9971	12

据表5-4所示, 在所有集成 Stacking 的模型中, 结合 PLSR、BPNN 和 AdaBoost 的 Stacking 模型预测性能是最好的, 它的 R_P^2 为 0.9953, RMSEP 值为 0.0086, RPD 为 14.5527, 证明使用 Kendall 相关分析组合基学习器的有效性。在 16 个模型中, 可以发现, 三个基学习器组合模型中预测效果最优的前 3 个模型为 PLSR_BPNN_AdaBoost、SVR_BPNN_AdaBoost 和 PLSR_SVR_AdaBoost, 四个基学习器组合模型中预测效果最优的前 2 个模型为 PLSR_SVR_BPNN_AdaBoost 和 PLSR_SVR_RF_AdaBoost, 均包含单一性能最好的模型 AdaBoost, 并且并未包含 AdaBoost 模型的 PLSR_SVR_BPNN、PLSR_BPNN_RF 和 SVR_BPNN_RF 在三种组合模型中预测效果最差, 这表明基学习器选择当中首先关注基学习器

的本身的预测性能。

在模型数量的选择方面, 需要根据特定问题选择合适的模型数量。在近红外光谱含水率预测中, 结合使用三种或四种基学习器均可获得良好的预测效果, 使用五种基学习器的效果最差。因此模型数量过多可能会影响基准学习器 AdaBoost 的预测能力, 使其受到其他模型误差的影响, 造成整体预测性能下降。

针对与 Adaboost 的 Kendall 相关分析, RF 模型表现出最高的相关系数。在使用三种基学习器进行组合的模型中, PLSR_RF_AdaBoost、SVR_RF_AdaBoost 及 BPNN_RF_AdaBoost 均为 RF 和 AdaBoost 的组合模型, 但其排名分别为 13、10 和 6, 整体表现欠佳。这可能是因为 Adaboost 采用 RF 作为基准学习器, 两者之间原理相似, 导致性能不佳。相反, PLSR_BPNN_AdaBoost、PLSR_SVR_AdaBoost 以及 SVR_BPNN_AdaBoost 使用的基学习器原理各不相同, 其排名分别为 1、2 及 5。因此选择与 Adaboost 相关度低的基学习器作为基模型, 应优先选择原理不同、独立性强的模型。这样可以最大程度地发挥各个模型的优点, 使得集成 Stacking 模型能够综合利用各个模型的特点, 减少可能出现的过度拟合情况, 以提高模型的泛化能力和预测精度。

5.5.2 改进 Stacking 集成学习的预测结果对比

本文首先依据 Kendall 相关性分析, 选出 PLSR、BPNN 和 AdaBoost 模型作为基学习器, 使用自适应遗传算法 (AGA) 优化 PLSR、BPNN 和 AdaBoost 模型的超参数, 选择 RF 作为元学习器, 以此建立改进 Stacking 集成学习模型。为了比较改进 Stacking 模型的预测性能, 本文将未经 AGA 优化的基学习器建立 Stacking 集成学习模型与改进型 Stacking 集成学习模型进行对比, 并以 AGA 优化后的 PLSR、BPNN 和 AdaBoost 模型的预测结果作为对照, 结果如表 5-5 所示。

表 5-5 基学习器和改进 Stacking 模型预测性能比较

模型	R_{CV}^2	RMSECV(%)	R_P^2	RMSEP(%)	RPD
AGA-PLSR	0.9653	2.33	0.9664	2.30	5.4571
AGA-BPNN	0.9941	0.94	0.9772	1.89	6.6286
AGA-AdaBoost	0.9970	0.51	0.9915	1.16	10.8345
Stacking	0.9787	1.83	0.9760	1.94	6.4612
改进 Stacking	0.9959	0.73	0.9953	0.86	14.5527

根据表 5-5, 可以发现在基学习器中, AGA-AdaBoost 在训练集中的预测性能最佳。该模型的训练集的 5 折交叉验证决定系数和均方根误差, 以及预测集的决定系数和均方根误差, 以及相对预测偏差分别为 0.9970、0.51%、0.9915、1.16% 和

10.8345。然而,在预测集中,AGA-AdaBoost 模型的准确性明显低于训练集。该模型的决定系数降低了 0.0055,均方根误差增加了 0.65%。同样地,AGA-BPNN 的决定系数和均方根误差也降低了 0.0169 和增加了 0.95%。虽然 AGA-PLSR 模型的预测集性能没有下降的情况,但是其预测精度较低,不适用于本次研究。因此,尽管单个模型在训练集上表现良好,由于绿茶含水率和光谱特征之间存在复杂的非线性关系,导致该模型的泛化能力较差,难以准确检测绿茶加工过程中的含水率。未改进的 Stacking 集成模型训练集的 5 折交叉验证决定系数和均方根误差,以及预测集的决定系数和均方根误差,以及相对预测偏差分别为 0.9787、1.83%、0.9760、1.94% 和 6.4612。在预测集和训练集预测效果相差较小,但由于未对基学习器的超参数进行优化,未改进的 Stacking 集成模型预测精度较低,不如 AGA-AdaBoost 模型,与 AGA-BPNN 相当,优于 AGA-PLSR。

图5-10展示了三种基学习器和 Stacking 集成学习模型在预测集上的结果对比。从图5-10和表5-5可以看出,Stacking 集成学习模型具有防止过拟合和降低误差的作用。改进后的 Stacking 集成学习模型在预测集中的决定系数为 0.9953,相较于 AGA-PLSR、AGA-BPNN 和 AGA-SVR 三种基学习器,提升了分别为 2.89%、1.81% 和 0.42%,平均提升为 1.71%;均方根误差为 0.86%,相较于基学习器分别降低了 1.44%、1.03% 和 0.3%,平均降低了 0.92%;RPD 为 14.5527,相较于基学习器增加了分别为 9.0956、7.9241 和 3.7182,平均增加了 6.5793。




图 5-10 基学习器和 Stacking 模型预测结果比较

图5-11展示了三种基学习器和 Stacking 集成学习模型在预测集上的预测偏差对比。从图5-11可知,AGA-PLSR 的预测偏差范围为-5.4562%到 7.6589%,平均绝对偏差为 1.7587%,AGA-BPNN 的预测偏差范围为-6.2986%到 7.2604%,平均绝对偏差为 1.3730%;AGA-AdaBoost 的预测偏差范围为-6%到 4.8250%,平均

绝对偏差为 0.5127%; Stacking 的预测偏差范围为 -6.1522% 到 5.2985%, 平均绝对偏差为 1.3625%; 改进后 Stacking 的预测偏差范围为 -3% 到 3%, 平均绝对偏差为 0.4781%。可以发现改进 Stacking 集成学习的偏差相对于其他模型预测偏差在绿茶含水率预测更小, 预测更稳定。




图 5-11 基学习器和 Stacking 模型预测偏差比较

综上所述, 改进 Stacking 集成学习模型相较于单一模型具有降低预测误差、提高模型预测精度和泛化能力的优势。它结合了各个模型的优点, 减少了单个学习器的缺陷, 同时获得了每个学习器中更多的信息。改进后的 Stacking 集成学习模型在绿茶加工含水率的近红外光谱检测中表现出更高的预测性能, 为绿茶含水率提供了新方法。

5.6 本章小结

本章针对绿茶含水率检测中单一模型的低精度、不稳定和泛化能力差的问题, 提出了改进的 Stacking 集成学习模型以提高性能和泛化能力。对基学习器的组合进行了 Kendall 相关性分析, 并介绍了 Stacking 集成学习算法的原理。使用 5 折交叉验证提升改进的 Stacking 模型的预测稳定性。引入自适应遗传算法对基学习器的超参数进行了优化, 并验证了 Kendall 相关性分析方法的有效性。最后比较了 Stacking 集成学习和基学习器在绿茶含水率检测中的性能, 为绿茶含水率检测提供了一种新方法。

第 6 章 总结与展望

6.1 总结

本文采用近红外光谱来检测加工中绿茶的含水率，这是确保绿茶加工质量和提高绿茶生产效率的关键。为解决近红外光谱中数据冗余和多种噪音对模型预测精度的影响，本研究通过实验分析采用多种预处理方法、特征波长选择算法和定量回归模型，并筛选出预测效果最佳的模型。为解决单一模型预测精度低、稳定性低和泛化能力弱等问题，本研究在绿茶含水率检测中应用了 Stacking 集成学习，并利用 Kendall 相关性分析改进了基学习器的组合。同时，采用自适应遗传算法优化基学习器的超参数，以实现加工中绿茶含水率的准确检测，并探究了集成学习在绿茶含水率检测中的有效性和可行性。

(1) 由于近红外光谱采集过程中不可避免地出现漂移和噪声现象，导致数据集中可能存在奇异样本。本文采用 MCCV 方法识别数据集中的奇异样本，筛选出了 18 个可疑奇异样本，并通过二次检验剔除了编号为 96、246、255、282、289 和 428 号的六个样本。并使用 SPXY 算法将数据集划分为训练集和预测集。使用 MSC、SNV、SG 平滑、DWT、FD、SD 和 DT 共七种方法进行预处理，对预处理后的光谱数据建立 PLSR 模型。实验结果表明，使用 SG 平滑方法的 PLSR 模型表现最佳，其预测集决定系数 R_p^2 为 0.9642，预测集均方根误差 RMSEP 为 2.37%，相对预测偏差 RPD 为 5.2825。

(2) 由于原始光谱中存在大量冗余信息和干扰信息，会影响预测模型的准确性，本文采用了 PCA、CARS、SPA 这三种提取特征波长，并建立 PLSR、SVR 和 BPNN 三种回归模型。结果表明，在特征波长提取方法的选择上，采用 PCA 提取特征波长的方法效果最佳。在回归模型方面，SVR 模型的预测结果更加准确。综合考虑模型的表现和泛化能力，PCA+SVR 模型表现最佳，其 R_p^2 为 0.9760，RMSEP 为 1.94%，RPD 为 6.4587。

(3) 为了解决单一模型精度低、不稳定和泛化能力差的问题，本研究采用了 Stacking 集成学习模型来建立绿茶含水率模型。通过自适应遗传算法 AGA 优化了 PLSR、SVR、BPNN、RF 和 AdaBoost 等五种回归模型的超参数。结果表明，AGA 显著提高了模型的预测精度。其中，AdaBoost 回归模型预测效果最佳，其 R_p^2 、RMSEP 和 RPD 分别为 0.9915、1.16% 和 10.8345。在基学习器的组合选择中，采用了 Kendall 相关性分析进行改进，并建立了 16 种基学习器的组合，验证了 Kendall 相关性分析的有效性和准确性。本文结合 AGA 优化模型超参数和 Kendall 相关性分析，建立了改进的 Stacking 模型，该模型以 AdaBoost、PLSR

和 BPNN 作为基学习器, RF 作为元学习器, 该模型表现最佳, 其 R_p^2 为 0.9953, RMSEP 为 0.86%, RPD 为 14.5527。

本文基于近红外光谱技术, 应用了特征波长提取方法和集成学习算法进行高效检测绿茶含水率。这些模型具有稳定性、预测能力和泛化性强, 能够实现绿茶含水率的快速无损检测, 可应用于绿茶加工过程中的含水率检测。有助于保障绿茶的加工品质并提升加工效率。未来的研究可以收集不同品种的绿茶样本信息, 持续扩充和维护模型, 提高其适用性, 并进一步推动绿茶加工的自动化发展, 实现更好的经济效益。

6.2 研究与展望

本文以基于近红外光谱技术对绿茶加工含水率进行检测为背景, 引入了多种方法对光谱进行预处理和波长选择, 并采用自适应遗传算法和 Stacking 集成学习优化模型, 取得了一定的研究成果。然而, 本研究存在以下不足和未来需要解决的问题:

(1) 需要进一步改进光谱数据的预处理方法和波长选择方法, 提高预处理方法的去噪能力和特征波长选择的准确性。

(2) 虽然引入了自适应遗传算法对模型的参数进行优化, 提高了算法的优化效果, 但优化的模型参数范围有限且应用的模型也有限, 希望进一步探索更多参数和模型在绿茶含水率检测中的应用。

(3) 虽将改进 Stacking 集成学习应用于绿茶加工中的含水率检测, 然而目前采集的数据集有限, 希望下一步能够获取更多数据, 对 Stacking 集成学习进行进一步改进, 例如 Stacking 集成学习与波长选择算法进行结合、探索更优的基学习器组合方式, 以此探索更优的绿茶含水率检测方法。

参考文献

- [1] Pan S Y, Nie Q, Tai H C, et al. Tea and tea drinking: China' s outstanding contributions to the mankind [J]. Chinese Medicine, 2022, 17(1): 1-40.
- [2] 王雪. 不同碧螺春中咖啡碱含量的分析研究 [J]. 农产品加工, 2019(15): 58-60.
- [3] Xu X Y, Zhao C N, Cao S Y, et al. Effects and mechanisms of tea for the prevention and management of cancers: An updated review [J]. Critical Reviews in Food Science and Nutrition, 2020, 60(10): 1693-1705.
- [4] Truong V L, Jeong W S. Antioxidant and anti-inflammatory roles of tea polyphenols in inflammatory bowel diseases [J]. Food Science and Human Wellness, 2022, 11(3): 502-511.
- [5] Jeon D B, Hong Y S, Lee G H, et al. Determination of volatile organic compounds, catechins, caffeine and theanine in jukro tea at three growth stages by chromatographic and spectrometric methods [J]. Food Chemistry, 2017, 219: 443-452.
- [6] 潘蓉, 赵学尽, 杜建斌, 等. 2021 年中国茶叶进出口贸易情况简析 [J]. 中国茶叶, 2022.
- [7] 张义丰, 刘春腊, 谭杰, 等. 新时期中国茶旅一体化发展及前景分析 [J]. 资源科学, 2010, 32(1): 78-87.
- [8] 李艳霞, 李含芬, 赵磊, 等. 消费者日常茶叶饮用习惯对健康的影响 [J]. 农学学报, 2017, 7(2): 91-95.
- [9] 朱宏凯, 董春旺, 张坚强, 等. 叶温、含水率对针芽绿茶感官品质的影响 [J]. 中国食品学报, 2016, 16(4): 224-236.
- [10] Wei Y, Wu F, Xu J, et al. Visual detection of the moisture content of tea leaves with hyperspectral imaging technology [J]. Journal of Food Engineering, 2019, 248: 89-96.
- [11] 徐海卫, 谭和平, 李刚, 等. 滚筒式茶叶杀青机导叶板螺旋运动模型研究 [J]. 茶叶科学, 2019, 34(4): 381-386.
- [12] Huang Z, Sanaeifar A, Tian Y, et al. Improved generalization of spectral models associated with vis-nir spectroscopy for determining the moisture content of different tea leaves [J]. Journal of Food Engineering, 2021, 293: 110374.
- [13] Li X, Xie C, He Y, et al. Characterizing the moisture content of tea with dif-

- fuse reflectance spectroscopy using wavelet transform and multivariate analysis [J]. *Sensors*, 2012, 12(77): 9847–9861.
- [14] 段东瑶, 赵丽清, 殷元元, 等. 绿茶加工过程含水率变化规律及预测模型研究 [J]. *中国农机化学报*, 2022, 43(3): 75.
- [15] 李雪, 王督, 白艺珍, 等. 我国油料产品品质的近红外光谱快速检测技术研究进展 [J]. *分析测试学报*, 2020, 39(10): 1189–1195.
- [16] 王清. 近红外光谱检测技术在农业与食品分析中的应用 [J]. *智慧农业导刊*, 2022, 2(16): 63–65.
- [17] 邹志云, 孟磊, 刘英莉, 等. 近红外光谱检测技术在精细化工生产过程中的应用 [J]. *计算机与应用化学*, 2018, 35(10): 809–820.
- [18] Kranenburg R F, Weesepeel Y, Alewijn M, et al. The importance of wavelength selection in on-scene identification of drugs of abuse with portable near-infrared spectroscopy [J]. *Forensic Chemistry*, 2022, 30: 100437.
- [19] 辛娜, 郭亮, 邓露芳, 等. 近红外光谱技术在饲料氨基酸检测中的研究进展 [J]. *饲料研究*, 2021, 44(9): 143–145.
- [20] Sanaeifar A, Huang X, Chen M, et al. Nondestructive monitoring of polyphenols and caffeine during green tea processing using vis-nir spectroscopy [J]. *Food Science & Nutrition*, 2020, 8(11): 5860–5874.
- [21] Zhuang X, Wang L, Chen Q, et al. Identification of green tea origins by near-infrared (nir) spectroscopy and different regression tools [J]. *Science China Technological Sciences*, 2017, 60(1): 84–90.
- [22] Jin G, Wang Y, Li L, et al. Intelligent evaluation of black tea fermentation degree by ft-nir and computer vision based on data fusion strategy [J]. *LWT*, 2020, 125: 109216.
- [23] 刘奇, 欧阳建, 刘昌伟, 等. 茶叶品质评价技术研究进展 [J]. *茶叶科学*, 2022, 42(3): 316–330.
- [24] 章恩宽, 徐彬, 王娟娟. 信阳毛尖茶传统手工炒制技艺 [J]. *茶叶通讯*, 2013, 40(2): 27–28.
- [25] 敖继红, 唐文洁, 李思臻. 食品安全中国国家标准 GB5009.3-2016《食品中水分的测定》与蒙古 MNS6477:2014《肉与肉制品水分测定方法》比对分析报告 [J]. *中国标准化*, 2019(1): 112–117.
- [26] 孙巧红, 伊博文, 闫小平, 等. 多功能红外水分测定仪快速测定颗粒剂水分含量 [J]. *时珍国医国药*, 2016, 27(10): 2408–2409.
- [27] 张榆晗, 曲韵智, 赵丽莹. 卤素水分测定仪快速测定 5 种中药材含水量 [J]. 黑

- 龙江科学, 2022, 13(6): 10–13.
- [28] Ezeanaka M C, Nsor-Atindana J, Zhang M. Online low-field nuclear magnetic resonance (1f-nmr) and magnetic resonance imaging (mri) for food quality optimization in food processing [J]. Food and Bioprocess Technology, 2019, 12(9): 1435–1451.
- [29] 苏悟, 郑小芬, 范琳, 等. 应用核磁共振法研究豆豉发酵过程中水分的变化规律 [J]. 粮油食品科技, 2014, 22(1): 95–99.
- [30] 陆静霞. 基于电容式传感器的粮食水分测量仪的研究 [J]. 农机化研究, 2005 (6): 122–123.
- [31] 张本华, 钱长钱, 焦晋康, 等. 基于介电特性与 SPA-SVR 算法的水稻含水率检测方法 [J]. 农业工程学报, 2019, 35(18): 237–244.
- [32] Seewattanapon S, Tripetch K, Lertwiriaprapa T, et al. Moistem by using microwave sensor [C]//2019 Research, Invention, and Innovation Congress (RI2C). 2019: 1–4.
- [33] Javanbakht N, Xiao G, Amaya R E. A comprehensive review of portable microwave sensors for grains and mineral materials moisture content monitoring [J]. IEEE Access, 2021, 9: 120176–120184.
- [34] 褚璇, 王伟, 赵昕, 等. 近红外光谱和特征光谱的山茶油掺假鉴别方法研究 [J]. Spectroscopy and Spectral Analysis, 2017, 37(1): 75–79.
- [35] Liang L, Fang G, Deng Y, et al. Determination of moisture content and basic density of poplar wood chips under various moisture conditions by near-infrared spectroscopy [J]. Forest Science, 2019, 65(5): 548–555.
- [36] Malvandi A, Feng H, Kamruzzaman M. Application of nir spectroscopy and multivariate analysis for non-destructive evaluation of apple moisture content during ultrasonic drying [J]. Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy, 2022, 269: 120733.
- [37] Makky M, Santosa, Putri R E, et al. Determination of moisture content in rice using non-destructive short-wave near infrared spectroscopy [J]. AIP Conference Proceedings, 2019, 2155(1): 020014.
- [38] 陈琳, 董春旺, 高明珠, 等. 基于近红外光谱的红茶干燥中含水率无损检测方法 [J]. 茶叶科学, 2016, 36(2): 184–190.
- [39] 李晓丽, 程术希, 何勇. 基于漫反射光谱的初制绿茶含水率无损检测方法 [J]. 农业工程学报, 2010, 26(5): 195–201.
- [40] 胡永光, 陈培培, 赵梦龙. 绿茶杀青叶料含水率可见-近红外光谱检测 [J]. 农

- 业机械学报, 2013, 44(8): 174–179.
- [41] Zhang M, Guo J, Ma C, et al. An effective prediction approach for moisture content of tea leaves based on discrete wavelet transforms and bootstrap soft shrinkage algorithm [J]. *Applied Sciences*, 2020, 10(1414): 4839.
- [42] Shen S, Hua J, Zhu H, et al. Rapid and real-time detection of moisture in black tea during withering using micro-near-infrared spectroscopy [J]. *LWT*, 2022, 155: 112970.
- [43] 高荣强, 范世福. 现代近红外光谱分析技术的原理及应用 [J]. *分析仪器*, 2002 (3): 9–12.
- [44] Fu X, Ying Y. Food safety evaluation based on near infrared spectroscopy and imaging: A review [J]. *Critical Reviews in Food Science and Nutrition*, 2016, 56 (11): 1913–1924.
- [45] Landi Jr S, Segundo I R, Freitas E, et al. Use and misuse of the kubelka-munk function to obtain the band gap energy from diffuse reflectance measurements [J]. *Solid state communications*, 2022, 341: 114573.
- [46] Li B, Zhang F, Liu Y, et al. Quantitative study of impact damage on yellow peaches based on reflectance, absorbance and kubelka–munk spectral data [J]. *RSC advances*, 2022, 12(43): 28152–28170.
- [47] Büning-Pfaue H. Analysis of water in food by near infrared spectroscopy [J]. *Food Chemistry*, 2003, 82(1): 107–115.
- [48] Konovalov D A, Sim N, Deconinck E, et al. Statistical confidence for variable selection in qsar models via monte carlo cross-validation [J]. *Journal of chemical information and modeling*, 2008, 48(2): 370–383.
- [49] Dai J, Chen P, Chu X, et al. Comparison between nir, ft-ir and raman for quantitative analysis of the conversion of poly alpha oil (pao) [J]. *Vibrational Spectroscopy*, 2022, 123: 103452.
- [50] 顾瀚文, 谢凯文, 江河, 等. 基于近红外光谱的预处理及组合方法 [J]. *激光与光电子学进展*, 2021, 58(16): 1617001.
- [51] 尼珍, 胡昌勤, 冯芳. 近红外光谱分析中光谱预处理方法的作用及其发展 [J]. *药物分析杂志*, 2008, 28(5): 824–829.
- [52] 魏玉震. 基于光谱和光谱成像技术的茶叶含水率检测机理和方法研究 [D]. 浙江大学, 2019.
- [53] 王立琦, 朱秀超, 张礼勇. 基于小波分析的近红外光谱数据预处理 [J]. *哈尔滨商业大学学报: 自然科学版*, 2009(6): 700–702.

- [54] 芦永军, 曲艳玲, 宋敏. 近红外相关光谱的多元散射校正处理研究 [J]. 光谱学与光谱分析, 2007, 27(5): 877-880.
- [55] 张辉, 吴迪, 李想, 等. 近红外光谱快速检测食用油必需脂肪酸 [J]. 农业工程学报, 2012, 28(7): 266-270.
- [56] Shi X, Yao L, Pan T, et al. Visible and near-infrared spectroscopy with multi-parameters optimization of savitzky-golay smoothing applied to rapid analysis of soil cr content of pearl river delta [J]. Journal of Geoscience and Environment Protection, 2021, 9(03): 75.
- [57] 罗斯特, 李增勇, 张明, 等. 基于小波变换的体内外酒精含量近红外光谱检测与分析 [J]. 光谱学与光谱分析, 2012, 32(06): 1541-1546.
- [58] 曹璞, 潘涛, 陈星旦. 小型近红外玉米蛋白质成分分析仪器设计的波段选择 [J]. 光学精密工程, 2007, 15(12): 1952-1958.
- [59] 陈华才, 吕进, 春红, 等. 近红外光谱法测定茶多酚中总儿茶素含量 [J]. 中国计量学院学报, 2005, 16(1): 17-20.
- [60] 王远辉, 黎庆涛, 姜毅, 等. 在线检测白砂糖近红外光谱的预处理方法研究 [J]. 食品科技, 2009(8): 283-286.
- [61] 孟庆琰, 何建国, 刘贵珊, 等. 基于近红外光谱技术的马铃薯全粉蛋白质无损检测 [J]. 食品科技, 2015(3): 287-291.
- [62] Liu Z, Zhang R, Yang C, et al. Research on moisture content detection method during green tea processing based on machine vision and near-infrared spectroscopy technology [J]. Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy, 2022, 271: 120921.
- [63] 褚小立, 袁洪福, 陆婉珍. 近红外分析中光谱预处理及波长选择方法进展与应用 [J]. 化学进展, 2004, 16(04): 528.
- [64] 侯振雨, 蔡文生, 邵学广. 主成分分析-支持向量回归建模方法及应用研究 [J]. 分析化学, 2006, 34(5): 617-620.
- [65] 彭海根, 金楹, 詹筱国, 等. 近红外光谱技术结合竞争自适应重加权采样变量选择算法快速测定土壤水解性氮含量 [J]. 分析测试学报, 2020, 39(10): 1305-1310.
- [66] 崔海, 余鑫磊, 庞继伟, 等. 采用 BP-ANN 和改进 SVR 的进水 BOD 软测量模型 [J]. 哈尔滨工业大学学报, 2022, 54(02): 59-66.
- [67] 陈方圆, 周鑫, 陈奕云, 等. 不同核函数支持向量机和可见-近红外光谱的多种植被叶片生化组分估算 [J]. 光谱学与光谱分析, 2019, 39(2): 428.
- [68] 阎平凡, 张长水. 人工神经网络与模拟进化计算 [M]. 清华大学出版社有限公

- 司, 2005.
- [69] Henseler J. Back propagation [J]. *Artificial Neural Networks: An Introduction to ANN Theory and Practice*, 2005: 37-66.
- [70] 姚雅琪, 徐秀丽. 基于 Stacking 集成学习的电影票房预测研究 [J]. *Statistics and Application*, 2021, 10: 193.
- [71] 李叶紫, 王振友, 周怡璐, 等. 基于贝叶斯最优化的 Xgboost 算法的改进及应用 [J]. *广东工业大学学报*, 2017, 35(01): 23-28.
- [72] 倪鸿飞, 斯乐婷, 黄家鹏, 等. 近红外光谱结合遗传算法优化的极限学习机实现银杏叶纯化过程有效成分快速测定 [J]. *中国中药杂志*, 2021, 46(1): 110-117.
- [73] 耿莹蕊, 沈欢超, 倪鸿飞, 等. 近红外光谱结合灰狼算法优化支持向量机实现烟叶产地快速鉴别 [J]. *Spectroscopy and Spectral Analysis*, 2022, 42(9): 2830-2835.
- [74] 叶娜, 黎天宇, 蔡东风, 等. 利用依存句法关系改进神经译文质量估计 [J]. *中文信息学报*, 2021, 35(9): 46-57.
- [75] Choi S, Hur J. An ensemble learner-based bagging model using past output data for photovoltaic forecasting [J]. *Energies*, 2020, 13(6): 1438.
- [76] Ni L, Wang D, Wu J, et al. Streamflow forecasting using extreme gradient boosting model coupled with gaussian mixture model [J]. *Journal of Hydrology*, 2020, 586: 124901.
- [77] Li M, Yan C, Liu W. The network loan risk prediction model based on convolutional neural network and stacking fusion model [J]. *Applied Soft Computing*, 2021, 113: 107961.
- [78] 李盛芳, 贾敏智, 董大明, 等. 随机森林算法的水果糖分近红外光谱测量 [J]. *光谱学与光谱分析*, 2018, 38(6): 1766-1771.
- [79] Min H, Luo X. Calibration of soft sensor by using just-in-time modeling and adaboost learning method [J]. *Chinese journal of chemical engineering*, 2016, 24(8): 1038-1046.
- [80] Cui S, Yin Y, Wang D, et al. A stacking-based ensemble learning method for earthquake casualty prediction [J]. *Applied Soft Computing*, 2021, 101: 107038.
- [81] 康琦, 安静, 汪镭, 等. 自然计算的研究综述 [J]. *电子学报*, 2012, 40(3): 548.
- [82] 陶焕明, 高美凤. 基于改进免疫遗传算法的近红外光谱变量选择方法 [J]. *分析测试学报*, 2021, 40(10): 1482-1488.

攻读学位期间主要的研究成果

一、学术论文

[1] An adaptive genetic algorithm optimizes double-hidden layer BPNN for rapid detection of moisture content of green tea in processing[J]. Journal of Food Processing and Preservation. **(SCI Under Review, JCR 2 区)**

二、主持和参与的科研项目

[1] 茶叶智能化加工及茶制品应用关键技术研究示范，参与

[2] 国家现代农业产业技术体系资助项目：国家茶叶产业技术体系智能化管理岗位科学家，参与

致 谢

时光荏苒，转眼间我即将完成硕士研究生学业，我在此要感谢所有曾经帮助过我的人。在研究生生涯，我要特别感谢我的导师、朋友、同门、室友和父母的帮助和支持。

首先，我要衷心感谢我的导师汤哲教授。他在我进行科研和论文写作的过程中给予了我耐心细致的指导，无论是学术上的问题还是生活中的困难，他都给予了我热情的帮助和支持，让我受益匪浅。他渊博的知识、严谨的治学态度、一丝不苟的工作作风和对科学事业的热爱，深深地感染着我，让我深刻地认识到做科研的意义和价值，对我的学术研究和人生道路产生了深远的影响。

其次，我要感谢我的朋友和同门。在这里，我要感谢我的实验室同门，我们一起讨论问题、分享知识和经验，互相激励、互相帮助。我们的友谊使我在紧张的学习生活中得到了宝贵的情感支持，让我更加坚定了学术研究的决心。同时，我还要感谢和我一起度过美好研究生时光的室友，我们一起分享生活的喜怒哀乐，让我感受到家的温暖和团结。

最后，我要特别感谢我的父母。他们是我一直以来最坚实的后盾，他们一直默默地支持我、鼓励我、理解我，让我在追逐梦想的道路上始终充满勇气和信心。他们的爱和支持是我前进的不竭动力，我将一直珍惜和回报他们。

在这篇毕业论文即将完成的时刻，我感到非常荣幸和感激。在此我要向答辩委员会的各位老师表示由衷的感谢，感谢您们在百忙之中抽出时间来审阅我的毕业论文。感谢您们的指导、帮助和建议，让我的论文能够得到提高和完善。感谢中南大学的各位老师和同学，向所有帮助过我的人表示深深的感谢和敬意！